

Кросс-возрастная верификация лиц по добытым парам одного человека из соцсетей

Д. Ф. Вольхин И. С. Копылов

НИУ «Высшая школа экономики», Москва, Россия deneal123@mail.ru

Русское зеркало для проверки. Это не материал для подачи в AAAI: шаблон AAAI запрещает кириллицу в тексте, поэтому официальная подача — англоязычная (. . /en/).

Аннотация. Кросс-возрастная верификация лиц — определить, изображён ли на двух снимках с разницей в годы один человек — сложна, а longitudinal-данные для обучения редки. Мы задаём *data-centric*-вопрос: можно ли получить супервизию для возрастной инвариантности без вручную размеченного longitudinal-набора? Мы показываем, что мультифото «тогда/сейчас»-посты дают слабые пары *одного человека* без ручных меток личности и возраста (LLM разбирает подписи, а кластеризация эмбеддингов формирует личности; компоненты мы аудируем, включая небольшую ручную валидацию), и что дообучение намеренно слабого распознавателя на них даёт *переносимую, целевую* устойчивость на больших возрастных разрывах. На внешнем бенчмарке FG-NET ROC-AUC на большом разрыве (≥ 25 лет) растёт с **0.736 до 0.848** ($+0.112 \pm 0.001$ по трём сидам; DeLong $p < 10^{-19}$) без измеримых потерь на лёгких бенчмарках (точность LFW $+0.004$, LFW TAR@FAR=0.1% $+0.002$; AgeDB-30 -0.008) — прирост сконцентрирован на режиме большого разрыва, а не разменян на потери. Наше центральное, ограниченное утверждение: внутри протокола атрибуции со слабым/средним backbone *источник данных*, а не выбор среди проверяемых целевых функций, объясняет бо́льшую часть прироста (контрастив совпадает с ArcFace-margin: 0.848 против 0.851). Прирост обеспечивается парностью одного человека (явные возрастные «якоря» из подписей дают лишь $+0.009$), механистически связан с устранением возрастного shortcut, превосходит реальную модель пере-старения при контроле паритета разрыва и переносится на независимую не-VK платформу.

1 Введение

Кросс-возрастная верификация лиц возникает в архивном поиске, восстановлении доступа и авторизованном поиске пропавших людей. Сложность не в различении произвольных людей, а в отделении *одного человека* сквозь *возраст* от *разных людей схожего возраста* и *внешности*. Разметка longitudinal-пар (один человек через много лет) дорога, и таких данных мало, что ограничивает supervised-подходы; недавние работы продолжают сообщать о слабой кросс-датасетной обобщаемости и нехватке качественных longitudinal-данных.

Гипотеза. Мультифото «тогда/сейчас»-пост с одним человеком в разном возрасте даёт $\binom{n}{2}$ позитивных пар без ручной разметки; подпись с возрастами добавляет вторичный возрастной «якорь». Парность одного человека — основной сигнал (абляция изолирует возрастной якорь на уровне лишь $+0.009$); это масштабируемый, слабо/естественно-супервизируемый сигнал кросс-возрастной идентичности, и дообучение слабого распознавателя на нём должно переноситься на внешние бенчмарки.

Вклад (ограниченный). (1) Слабо/естественно-супервизируемый (без ручных меток личности/возраста) longitudinal-сигнал из соцпостов — пары одного человека, где возрастные якоря лишь вторичны. (2) Строгий *протокол атрибуции* (один слабый обучаемый backbone, frozen против дообученного, внешняя оценка), изолирующий вклад *данных* от ёмкости сети. (3) Взаимоподкрепляющие контроли (семейство потерь, архитектура, источник-сообщество, целевая функция, реальное-против-синтетического, диагностика shortcut,

кросс-платформенный перенос), поддерживающие ограниченное утверждение, что внутри протокола и среди проверенных целей данные дают больше прироста на большом разрыве, чем выбор семейства потерь. (4) Конвейер очистки с аудитом автоматических компонентов и находкой, что наивный счёт позитивов завышен примерно вдвое near-duplicate-кадрами. Новизна *data-centric*, а не архитектурная — новый *источник супервизии*. Перенесённые ради места контроля и аудиты собраны в дополнительном техническом приложении.

2 Связанные работы и позиционирование

Наиболее релевантны три линии. *Дискриминативная возраст-инвариантная FR на размеченных данных*: OE-CNN [1], DAL [2], MTLFace [3] достигают высокой точности, но обучаются на наборах с *ручными метками личности и возраста* (CACD [4], MORPH [5], AgeDB [6], FG-NET [7]). *Кросс-возрастной контрастив с синтетикой*: SCACon [8] добавляет синтезированный кросс-возрастной образец и triplet-потерю; OrdCon [9] — order-enhanced контрастив. *Синтетическое старение*: систематические исследования показывают лишь частичную пользу синтетики [10]. Обобщённый self-supervised (аугментации в духе SimCLR [11]) лишён якорей идентичности во времени. Мы же добываем структуру «один пост = один человек в разном возрасте» как генератор позитивных пар без меток. Мы отчитываемся на канонических кросс-возрастных бенчмарках (AgeDB-30, CALFW [12], FG-NET; CALFW — более сложный, возрастно-разнесённый

LFW [13]). Цель — не превзойти абсолютный SOTA (мы берём слабый backbone ради чистой атрибуции), а изменить величину и переносимость прироста от естественно-супервизируемого источника; разд. 5.1 обучает каноническую SOTA-цель прямо на наших данных.

3 Данные: естественно-заякоренные longitudinal-пары

Источник. Два публичных «тогда/сейчас» мультифото-сообщества во ВКонтакте (одна платформа, русскоязычный контекст). Лица детектируются и выравниваются по 5-точечному шаблону ArcFace (InsightFace RetinaFace [14], buffalo_1). *Пригодное* лицо проходит проверки на det-score, минимальный размер, размытие и единственность цели. Сырой добытый корпус — в табл. 1.

Извлечение возраста. Подписи разбираются регулярными выражениями (русские паттерны плюс формат со слешами «6/18/21») и большой языковой моделью (LLM). По всем 33,697 мультифото-подписям LLM расширяет и регуляризует извлечение относительно regex (не читает календарные годы или разрывы как возраст, восстанавливает второй возраст), расходясь на 27.2% постов преимущественно в пользу LLM; на ручном эталоне из 100 подписей LLM совпал с человеком в 89% против 71% у regex (приложение). Выход LLM не считается истиной: ниже по конвейеру явные возрастные якоря дают лишь маргинальный вклад (разд. 5.1).

Личности и сплит без утечек. Наивное «один пост = одна личность» недосчитывает: человек повторяется в разных постах. Мы кластеризуем пост-группы в личности по близости эмбедингов (косинус ≥ 0.85), получая 21,848 личностей из 27,487 пост-групп ($\approx 20\%$ повторов), и делим *по человеку* (не по посту). Ручной осмотр показал, что косинус не отделяет двойников от одного человека в полосе 0.55–0.8, поэтому порог слияния намеренно консервативен.

Аудит супервизии. Автоматические компоненты — потенциальный скрытый шум меток, проверяемый тремя способами: согласие LLM и regex по возрасту; внутригрупповая согласованность кажущегося пола как дешёвый детектор нескольких людей; и *небольшая* ручная валидация (один аннотатор), которая *проверяет* конвейер на вменяемость (возраст, целостность групп, точность пар и слияний 0.93–0.96; приложение). С одним аннотатором и без межаннотаторной κ это *поддерживает*, но не *сертифицирует* супервизию; масштабный многоаннотаторный аудит вне наших ресурсов, поэтому остаточный шум честно отмечен как ограничение (разд. 7).

Очистка и её главная находка. Мы применяем полноточную агрегацию кажущегося пола/возраста, LLM-валидацию целостности групп (92.8% — один человек) и удаление near-duplicate внутри личности (косинус ≥ 0.97). Поскольку число позитивов квадратично по числу лиц в группе, удаление near-duplicate сократило счёт позитивов с 65,897 до 31,865 (–52%): **около половины сырых «по-**

зитивов» были дублирующими кадрами (одна съёмка, серия, репост), завышавшими внутренние метрики. После очистки frozen-базлайн на внутреннем тесте падает ($\text{our.25} + 0.705 \rightarrow 0.640$), обнажая более трудный и репрезентативный бенчмарк; внешние бенчмарки не затронуты. Сокращение устойчиво к порогу дедупа 0.93–0.97 (приложение). Поля происхождения, прав и governance хранятся поэлементно; полная карточка датасета [15] сопровождает релиз (см. раздел об этике).

4 Метод, протокол и статистика

Протокол атрибуции. Сравнить адаптер поверх замороженного сильного ArcFace с frozen ArcFace некорректно (адаптер лишь деформирует почти идеальные эмбединги). Вместо этого мы берём *один слабый обучаемый backbone* (FaceNet InceptionResNetV1 [16], CASIA-WebFace) и сравниваем (а) frozen $\rightarrow$ метрика против (б) мягкого дообучения головы на наших парах $\rightarrow$ метрика, с margin-контрастивной потерей. *Оценка — на внешних бенчмарках* (LFW, AgeDB-30, CALFW, FG-NET) ради чистой атрибуции переноса; внутренний тест (our.^*) — вторичная in-domain диагностика. Сила backbone варьируется (разд. 5.3). Дизайн меняет абсолютную производительность на *причинную атрибуцию*.

Backbone и метрики. FaceNet (слабый); ArcFace iResNet-50 [17] (слабый, другая архитектура); AdaFace IR-50/IR-101 [18] и ArcFace iResNet-100 (сильные; чистый контроль глубины). Сообщаем LFW (точность по 10 фолдам), AgeDB-30 и CALFW (ROC-AUC и точность) и FG-NET (ROC-AUC в целом и на подмножестве большого разрыва ≥ 25 лет), различая *беспороговые* метрики (ROC-AUC) и *пороговые* (точность, TAR@FAR). LFW считается на *выровненных* кропах: изображения пар заново детектируются RetinaFace и приводятся тем же 5-точечным `norm_score`, что и наши кропы (промахи детектора 0.36%). Это существенно: широко используемый загрузчик sklearn отдаёт невыровненные изображения, обрезанные до 125×94 , на которых распознаватели с margin-обучением рушатся (замороженный ArcFace r100 даёт там 0.83 при 0.98 на более сложном AgeDB-30). Абсолютные значения LFW при нашем выравнивании немного ниже опубликованных и не должны сравниваться с лидербордами; frozen и дообученные модели меряются одинаково, поэтому приведённые разности корректны.

Статистика. Основная конечная точка — ROC-AUC FG-NET на большом разрыве, нулевая гипотеза: дообучение не улучшает её относительно frozen (прирост ≤ 0); AgeDB-30, CALFW и внутренний кросс-возрастной тест вторичны, лёгкая точность LFW — контроль забывания. Headline-прирост — среднее $\pm \text{std}$ по трём сидам. Мы приводим bootstrap-ДИ, EER и TAR@FAR (внутренний тест дополнительно использует identity-level bootstrap), тест DeLong для двух *коррелированных* ROC-кривых [19], парный permutation-тест и поправку Холма по стратифицированным fairness-тестам (полные таблицы операционных

Этап	Постов	Фото	Пригодных лиц	Личностей (групп)	Позитивных пар
Сырой майнинг (2 сообщества)	44,609	84,147	49,606	21,848	65,897
После очистки	—	—	40,586	21,427	31,865

Таблица 1: Масштаб набора (сырой майнинг) и после очистки. Удаление near-duplicate-кадров примерно вдвое сокращает число позитивов.

точек — в приложении). Все headline-эксперименты — на очищенных данных (21,427 групп, 40,586 лиц, 31,865 позитивов; сплит по человеку со сбалансированными негативами).

5 Результаты

5.1 Главный эффект и абляция источника супервизии

Слабый FaceNet, мягко дообученный на наших парах, поднимает ROC-AUC FG-NET на большом разрыве с **0.736 до 0.848** ($+0.112 \pm 0.001$), при этом лёгкая LFW вовсе не падает ($+0.004$), а AgeDB-30/CALFW почти не меняются (табл. 2). Абляция изолирует источник: пары из одного поста не используют ручных меток и дают почти весь прирост; добавление явных возрастных якорей даёт лишь **+0.009** на бакете 25+. Метод, таким образом, *слабо супервизируется естественной со-встречаемостью в одном посте*, а возрастная супервизия маргинальна.

Bootstrap-ДИ (сид 42) подтверждают основную точку: FG-NET большой разрыв растёт с 0.736 [0.70, 0.78] до 0.848 [0.82, 0.88] с *непересекающимися* 95% ДИ; EER почти вдвое снижается ($0.335 \rightarrow 0.219$), а TAR@FAR=1% почти удваивается ($0.21 \rightarrow 0.39$). Поскольку пересечение bootstrap-ДИ игнорирует общие образцы двух моделей, мы подтверждаем точку тестом DeLong для коррелированных ROC [19]: на FG-NET большом разрыве $z = 9.3$, $p = 1.4 \times 10^{-20}$ (ΔAUC 95% ДИ [$+0.088$, $+0.135$]); парный permutation-тест (10^4) согласуется ($p < 10^{-4}$). Тот же тест показывает целевой характер: AgeDB-30 слегка снижается (-0.008 , $p = 4 \times 10^{-6}$), а CALFW неизменна ($p = 0.95$). Операционные точки (табл. 3) делают компромисс наглядным: AUC и TAR@1% на большом разрыве резко растут, а точки низкого FAR на лёгких бенчмарках (LFW TAR@0.1%) деградируют.

Инвариантность к целевой функции. Обучая канонические современные margin-цели — ArcFace, CosFace и SphereFace [17] (ядро OE-CNN/MTLFace) — на наших естественно-супервизируемых личностях при том же backbone и протоколе, контрастив, ArcFace и CosFace **совпадают** на основной точке (0.848 / 0.851 / 0.843, в пределах ± 0.006); лишь SphereFace, труднее всего оптимизируемый на 2–3-shot личностях без λ -annealing, отстаёт (0.801). Шумоустойчивый sub-center ArcFace [20] также даёт 0.851 — явная машинерия для шума меток ничего не добавляет на *очищенных* парах. Отсюда ограниченный вывод: внутри протокола и среди проверенных целей *источник данных* объясняет больше прироста, чем выбор

цели (полная таблица — в приложении, табл. 4).

5.2 Реальные пары превосходят синтетическое старение

Замена реальных позитивов синтетически состаренными — доменным прокси и реальной сетью пере-старения (FRAN [21]) — уступает реальным парам, а на дефолтном *широком* разрыве FRAN даже *падает* ниже frozen (FG-NET большой разрыв 0.727; табл. 5). Идентичность-сохраняющее старение воспроизводит текстурные артефакты, а не реальную longitudinal-вариативность (поза, камера, эпоха). Контроль на нативном разрешении исключает артефакт кропа: перекадрирование подмножества на 512px прямо из исходников и повторное старение не меняет результат (0.771 против 0.778). Контроль паритета разрыва уточняет картину: FRAN стареет на широкий разрыв 33–70 лет, тогда как у реальных пар медиана 9 лет; согласование синтетического разрыва с реальным распределением поднимает FRAN до **0.759** — скромный плюс, согласующийся с сообщаемыми приростами синтетики [10] — но реальные пары (0.848) всё равно ведут на $+0.089$. Реальные добытые пары обходят даже *согласованную по разрыву* модель пере-старения.

5.3 Headroom и масштабирование по данным

Прирост воспроизводится на FaceNet, ArcFace iResNet и AdaFace IR-50/IR-101 (три семейства потерь, две архитектуры) и *монотонно убывает с силой frozen* (рис. 1); чистый контроль глубины (AdaFace IR-50 $\rightarrow$ IR-101) это подтверждает. Сильные насыщенные backbone не улучшаются и слегка забывают при дообучении; мягкая скорость обучения вдвое снижает забывание, но не превращает его в прирост. Вклад, таким образом, специфичен для слабых и средних backbone с кросс-возрастным запасом — это ограничение мы прямо отмечаем (разд. 7). **Оговорка к этой кривой:** она измерена против *случайных* импостеров, которых современные backbone разделяют тривиально (замороженный IR-101 даёт $\text{our} .25+ = 0.968$). С похожими негативами (тот же кажущийся пол, $|\Delta\text{возраст}| \leq 5$ лет, ранжирование независимым майнером) IR-101 падает до 0.705 на rank-10 и 0.474 на rank-1, тогда как наши пары по-прежнему добавляют $+0.20 \dots +0.26$ слабому backbone; замороженная SOTA при этом значимо впереди на каждом уровне. Значит сильные backbone не улучшаются *нашей* супервизией, а не лишены кросс-возрастного запаса. При варьировании доли обучающих личностей

Метрика	Frozen	+pairs (среднее $\pm$ std)	Прирост	(До очистки)
FG-NET большой разрыв	0.7361	0.8484 $\pm$ 0.0007	+0.1124	+0.1215
FG-NET ROC	0.8955	0.9230 $\pm$ 0.0006	+0.0275	+0.0277
our.25+ (внутр.)	0.6403	0.8348 $\pm$ 0.0027	+0.1946	+0.1677
our.overall (внутр.)	0.8363	0.9163 $\pm$ 0.0009	+0.0801	+0.0764
LFW точность	0.9640	0.9679 $\pm$ 0.0002	+0.0039	n/a
AgeDB-30 ROC	0.9530	0.9462 $\pm$ 0.0013	-0.0068	-0.0155
CALFW ROC	0.9482	0.9489 $\pm$ 0.0014	+0.0007	-0.0030

Таблица 2: Главный результат: слабый FaceNet frozen против +pairs, три сида, очищенные данные (прирост до очистки — для справки). Эффект сосредоточен на подмножестве FG-NET с большим разрывом.

Бенчмарк	Frozen AUC [95% ДИ]	+pairs AUC [95% ДИ]	EER (fr. $\rightarrow$ p.)	TAR@1%	TAR@0.1%
FG-NET большой разрыв	0.736 [0.70, 0.78]	0.848 [0.82, 0.88]	0.335 $\rightarrow$ 0.219	0.209 $\rightarrow$ 0.386	0.074 $\rightarrow$ 0.154
FG-NET в целом	0.896 [0.89, 0.90]	0.922 [0.92, 0.93]	0.186 $\rightarrow$ 0.151	0.502 $\rightarrow$ 0.562	0.315 $\rightarrow$ 0.308
AgeDB-30	0.953 [0.95, 0.96]	0.945 [0.94, 0.95]	0.115 $\rightarrow$ 0.126	0.525 $\rightarrow$ 0.510	0.285 $\rightarrow$ 0.309
CALFW	0.948 [0.94, 0.95]	0.948 [0.94, 0.95]	0.116 $\rightarrow$ 0.117	0.580 $\rightarrow$ 0.624	0.213 $\rightarrow$ 0.320
LFW (AUC)	0.983 [0.98, 0.99]	0.986 [0.98, 0.99]	0.038 $\rightarrow$ 0.037	0.939 $\rightarrow$ 0.940	0.814 $\rightarrow$ 0.816

Таблица 3: Операционные точки и 95% bootstrap-ДИ (FaceNet frozen против +pairs, сид 42). LFW показан как ROC-AUC для единообразия.

Цель	FG-NET 25+	our.25+	LFW	AgeDB-30
Frozen	0.736	0.640	0.969	0.953
+pairs (контр.)	0.848	0.838	0.946	0.945
+ArcFace	0.851	0.868	0.952	0.947
+ArcFace, sub-center	0.851	0.869	0.951	0.947
+CosFace	0.843	0.860	0.952	0.945
+SphereFace	0.801	0.699	0.950	0.943

Таблица 4: Сравнение целей (FaceNet, очищенные): контрастив, ArcFace и CosFace совпадают на основной точке; sub-center ничего не добавляет; SphereFace отстаёт на разреженных few-shot личностях.

Метрика	Frozen	+реал.	syn-FRAN	FRAN-gm
FG-NET 25+	0.736	0.848	0.727	0.759
our.25+	0.640	0.838	0.549	0.622

Таблица 5: Реальные против синтетических позитивов (FaceNet, очищенные). FRAN-gm согласует синтетический возрастной разрыв с распределением реальных пар (медиана 9 лет).

(val/test фиксированы) прирост насыщается рано: **$\approx 96\%$ полного прироста FG-NET большого разрыва достигается уже на 10% личностей** ($\approx 1,500$), выходя на плато с 25% (рис. 2; каждая точка — среднее $\pm$ std по трём сидам). Сигнал данных-эффективен; дальнейший рост требует *более трудных* данных (большие разрывы, трудные позитивы), а не просто объёма.




Рис. 1: Кривая headroom: прирост +pairs на FG-NET большом разрыве монотонно сжимается с усилением frozen-backbone, пересекая ноль для сильных насыщенных моделей.

5.4 Механизм: возрастной shortcut

При age-matched негативах (тот же возрастной бакет, разные люди) точность frozen на внутреннем тесте 25+ падает с 0.640 до 0.517 (**около уровня случайности 0.5**), а реальные пары восстанавливают её до **0.838** (рис. 3) — прямое свидетельство, что frozen-модели различают кросс-возрастные пары в основном по *возрасту*, тогда как наши пары наводят различие по *идентичности*. Линейный проб уточняет это репрезентационно: кажущийся возраст остаётся хорошо декодируемым из эмбединга идентичности у *всех* моделей (≈ 0.63 – 0.65 сбалансированной точности $\gg 0.25$ случайности) и меняется слабо, то




Рис. 2: Закон масштабирования: внешний (FG-NET большой разрыв) и внутренний (our.25+) ROC-AUC против числа обучающих личностей (лог-шкала). Около 96% прироста достигается на 10% личностей; полосы — ± 1 std по трём сидам, пунктир — frozen-базлайны.

гда как AUC идентичности резко растёт (0.836→0.916) — метод учит инвариантную метрику (косинус перестаёт опираться на ось возраста), а не возраст-свободное представление; явное adversarial-разделение не снижает утечку дальше (приложение).

5.5 Кросс-платформенный и кросс-исходный перенос

Обучение на одном VK-сообществе и тест на отложенном другом переносит прирост (внешний FG-NET большой разрыв +0.113, практически как внутри-исходный +0.112). Более сильная внешняя проверка — обобщается ли источник за пределы платформы. Применяя идентичный протокол майнинга к независимому не-VK сообществу — доске Reddit t/PastAndPresentPics (тот же формат «тогда/сейчас», тот же LLM-парсер) — и оценивая VK-обученную +pairs-модель без Reddit-данных в обучении на 1,575 Reddit-парах, общий ROC-AUC растёт с **0.718 до 0.749** (+0.031, почти непересекающиеся 95% ДИ). Перенос *двунаправлен*: backbone, обученный *только* на малом 220-личностном Reddit-источнике (пилот, не headline), тоже помогает на VK (FG-NET большой разрыв +0.047). Прирост меньше, чем внутри VK (более шумный, частично коллажный набор), поэтому мы читаем его как подтверждение обобщения источника за платформу, а не SOTA-заявку. Рис. 4 показывает, что прирост +pairs остаётся *положительным на всех трёх* внешних оценках, сжимаясь на более трудных/шумных наборах.

Аудит по кажущимся демографиям. При стратификации по *кажущемуся* полу/возрасту якоря пары (оценочному, не самоидентифицированному) ни одна группа не деградирует, и каждый прирост значим (95% парный bootstrap-ДИ > 0; приложение). Наибольший прирост — у




Рис. 3: Возрастной shortcut: на тесте только-по-идентичности (age-matched негативы) frozen-модель падает почти до случайности; дообучение на наших парах восстанавливает различие по идентичности.

младшей группы 0–17 (0.750→0.880, +0.130), где базовая модель слабее всего, что подтверждается на *независимом* child↔adult подмножестве FG-NET (+0.129, непересекающиеся ДИ). При согласованном ≈1% FMR +pairs снижает FNMR в каждой кажущейся страте. Мы избегаем слова «справедливо» как решённого свойства: источник смещён к кажущемуся женскому полу (76.7%), а атрибуты кажущиеся, не юридические категории.

6 Обсуждение

Вклад — масштабируемый, слабо/естественно-супервизируемый источник longitudinal-супервизии, обучающий переносимой кросс-возрастной устойчивости, которую синтетическое старение не заменяет, а явная возрастная супервизия не объясняет. Взаимоподкрепляющие контроли (семейство потерь, архитектура, источник-сообщество, цель, шумоустойчивый margin) сходятся к ограниченному выводу: внутри протокола *источник данных* объясняет больше прироста на большом разрыве, чем выбор цели. Важно: улучшение — *целевой* прирост на большом разрыве, а не drop-in апгрейд универсального верификатора: улучшение *сконцентрировано* на режиме большого разрыва, а не равномерно, но это не размен: на корректно выровненном LFW все рабочие точки не хуже прежних (TAR@FAR=0.1% 0.814 → 0.816), а CALFW на низком FAR улучшается. В более ранней версии этого анализа сообщалось о существенной low-FAR-деградации; это был артефакт невыровненного пути оценки LFW, который не переживает исправления.

Объём утверждений. Установлено (внутри протокола атрибуции): (i) пары улучшают верификацию на большом разрыве на FG-NET (основная точка, непересекающиеся 95% ДИ) и внутреннем тесте 25+; (ii) прирост переносится между двумя сообществами, на независи-




Рис. 4: Внешнее обобщение. Прирост +pairs над frozen (95% ДИ) держится на трёх независимых оценках — FG-NET большой разрыв, child↔adult подмножество FG-NET и кросс-платформенный Reddit — везде выше случайности, наибольший на in-protocol FG-NET и меньший (но положительный) на более шумном Reddit.

мое child↔adult подмножество FG-NET и на не-VK платформу; (iii) реальные пары **превосходят синтетическое старение**, включая контроли нативного разрешения и паритета разрыва; (iv) прирост инвариантен к контрастиву, ArcFace и CosFace; (v) механистически связан с **устранением возрастного shortcut**; (vi) около половины сырых позитивов были near-duplicate-кадрами. *Не установлено / вне объёма*: это не равномерный прирост верификации (он сконцентрирован на подмножестве большого разрыва); сильные насыщенные backbone не улучшаются; больший не-VK обучающий источник с многосидовыми ДИ — дальнейшая работа; мы не воспроизводим полный SOTA-конвейер, только общую margin-цель; fairness-аудит использует лишь кажущиеся атрибуты без многоаннотаторной κ .

7 Ограничения

- **Зависимость от backbone**: прирост сосредоточен в слабых/средних backbone; сильные модели не улучшаются и слегка забывают. Они насыщены только против случайных импостеров — с похожими негативами они далеки от потолка, так что это ограничение *нашей* супервизии, а не задачи.
- **Внешняя валидность**: два VK-сообщества, одна платформа, один язык/культурный контекст; смещение к кажущемуся женскому полу (76.7%); разреженность при кажущемся возрасте 45+. Перенос показан между двумя VK-источниками, на стандартные внешние бенчмарки и на небольшой независи-

мый Reddit-тест «тогда/сейчас»; это не устанавливает платформно-агностичную обобщаемость.

- **Только кажущиеся атрибуты** в fairness-аудите (оценочные, не самоидентифицированные пол/ этничность) и без межаннотаторной κ (масштабный ручной аудит трудоёмок и вне наших ресурсов).
- **Слабо супервизируется, не label-free**: LLM разбирает возраст и валидирует целостность групп, а кластеризация формирует личности — проверено, но остаётся источником скрытого шума.
- **Масштаб и возраст бенчмарков**: стандартный кросс-возрастной набор (AgeDB-30, CALFW, FG-NET) обеспечивает сопоставимость, но наследует ограниченный масштаб/возраст; больший не-VK longitudinal-набор остаётся полезной дальнейшей работой.

Этика, правовая основа и data governance

Это чувствительное биометрическое исследование; governance мы рассматриваем как полноценный компонент. Разрешённое использование ограничено controlled / consent-based / human-reviewed приложениями (архивы и семейные фото с очищенными правами, авторизованный гуманитарный поиск, восстановление доступа); система выдаёт кандидатов для проверки человеком, а не автоматическое решение. Это *только исследовательская работа*: ничего не развёртывается и *не публикуется публичная биометрическая база*. Запрещено: массовая идентификация, деанонимизация, слежка и любая обработка данных несовершеннолетних без правовой основы.

Этическое одобрение. Формальный протокол этического комитета по данному исследованию на текущий момент не оформлялся; учитывая его исключительно исследовательский характер и полное обезличивание, авторы оформят этическую экспертизу организации или документированное освобождение, если этого потребует площадка или рецензенты. **Согласие.** Поскольку данные взяты из публичных постов без реальной возможности связаться с субъектами, индивидуальное информированное согласие не получалось; мы опираемся на научно-исследовательскую правовую основу с мерами обезличивания ниже и отмечаем, что официальный доступ к API и добровольная публикация сами по себе не дают права на биометрическую обработку (ср. спецкатегория по GDPR ст. 9 [22] и национальное право о согласии на биометрию).

Обезличивание и доступ. Мы *не публикуем сырые изображения лиц и сырые посты*. Публичный релиз ограничен кодом, конфигурациями, псевдонимизированным протоколом бенчмарка и агрегатной статистикой. Поскольку эмбединг лица сам по себе сравнимый *биометрический шаблон*, а солёные хеши не делают его анонимным, веса и эмбединги предоставляются добросовест-

ным исследователям *по запросу* в рамках краткого соглашения об использовании в исследовательских целях (только research; запрет реидентификации). Обезличенный набор данных также доступен по запросу, формальная документация по защите данных будет подготовлена при необходимости. Идентификаторы платформы заменяются солёными хешами; подписи/комментарии исключаются; хранятся только возрастной бакет и псевдонимный ID; элементы детского возраста исключаются из релиза без явных правовых рамок и согласия законного представителя. DPIA, полную карточку датасета [15] и процедуру удаления по запросу мы прилагаем к релизу.

Воспроизводимость. Мы публикуем все скрипты, конфигурации и версионированные LLM-промпты; сырые изображения и посты не публикуются, поэтому воспроизведение майнинга частично (мы публикуем кэшированные выходы LLM для детерминированного replay). Всё исследование выполняется на одном ноутбуке (одна GPU на 6 ГБ). Чек-лист воспроизводимости прилагается.

Список литературы

- [1] Y. Wang, D. Gong, Z. Zhou, X. Ji, H. Wang, Z. Li, W. Liu, and T. Mei, “Orthogonal deep features decomposition for age-invariant face recognition,” in *Proc. Eur. Conf. Comput. Vis. (ECCV)*, 2018, pp. 738–753.
- [2] H. Wang, D. Gong, Z. Li, and W. Liu, “Decorrelated adversarial learning for age-invariant face recognition,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2019, pp. 3527–3536.
- [3] Z. Huang, J. Zhang, and H. Shan, “When age-invariant face recognition meets face age synthesis: A multi-task learning framework,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2021, pp. 7282–7291.
- [4] B.-C. Chen, C.-S. Chen, and W. H. Hsu, “Cross-age reference coding for age-invariant face recognition and retrieval,” in *Proc. Eur. Conf. Comput. Vis. (ECCV)*, 2014, pp. 768–783.
- [5] K. Ricanek and T. Tesafaye, “MORPH: A longitudinal image database of normal adult age-progression,” in *Proc. IEEE Int. Conf. Autom. Face Gesture Recognit. (FG)*, 2006, pp. 341–345.
- [6] S. Moschoglou, A. Papaioannou, C. Sagonas, J. Deng, I. Kotsia, and S. Zafeiriou, “AgeDB: The first manually collected, in-the-wild age database,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. Workshops (CVPRW)*, 2017, pp. 51–59.
- [7] G. Panis, A. Lanitis, N. Tsapatsoulis, and T. F. Cootes, “Overview of research on facial ageing using the FG-NET ageing database,” *IET Biometrics*, vol. 5, no. 2, pp. 37–46, 2016.
- [8] H. Wang, V. Sanchez, and C.-T. Li, “Cross-age contrastive learning for age-invariant face recognition,” in *Proc. IEEE Int. Conf. Acoust. Speech Signal Process. (ICASSP)*, 2024, arXiv:2312.11195.
- [9] —, “From age estimation to age-invariant face recognition: Generalized age feature extraction using order-enhanced contrastive learning,” *arXiv preprint arXiv:2501.01760*, 2025.
- [10] W. Yao, M. A. Farooq, J. Lemley, and P. Corcoran, “Synthetic face ageing: Evaluation, analysis and facilitation of age-robust facial recognition algorithms,” *arXiv preprint arXiv:2406.06932*, 2024.
- [11] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, “A simple framework for contrastive learning of visual representations,” in *Proc. Int. Conf. Mach. Learn. (ICML)*, 2020, pp. 1597–1607.
- [12] T. Zheng, W. Deng, and J. Hu, “Cross-age LFW: A database for studying cross-age face recognition in unconstrained environments,” *arXiv:1708.08197*, 2017.
- [13] G. B. Huang, M. Ramesh, T. Berg, and E. Learned-Miller, “Labeled faces in the wild: A database for studying face recognition in unconstrained environments,” Univ. of Massachusetts, Amherst, Tech. Rep. 07-49, 2007.
- [14] J. Deng, J. Guo, E. Ververas, I. Kotsia, and S. Zafeiriou, “RetinaFace: Single-shot multi-level face localisation in the wild,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2020, pp. 5203–5212.
- [15] T. Gebru, J. Morgenstern, B. Vecchione, J. W. Vaughan, H. Wallach, H. Daumé III, and K. Crawford, “Datasheets for datasets,” *Commun. ACM*, vol. 64, no. 12, pp. 86–92, 2021.
- [16] F. Schroff, D. Kalenichenko, and J. Philbin, “FaceNet: A unified embedding for face recognition and clustering,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2015, pp. 815–823.
- [17] J. Deng, J. Guo, N. Xue, and S. Zafeiriou, “ArcFace: Additive angular margin loss for deep face recognition,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2019, pp. 4690–4699.
- [18] M. Kim, A. K. Jain, and X. Liu, “AdaFace: Quality adaptive margin for face recognition,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2022, pp. 18 750–18 759.
- [19] E. R. DeLong, D. M. DeLong, and D. L. Clarke-Pearson, “Comparing the areas under two or more correlated receiver operating characteristic curves: A nonparametric approach,” *Biometrics*, vol. 44, no. 3, pp. 837–845, 1988.

- [20] J. Deng, J. Guo, T. Liu, M. Gong, and S. Zafeiriou, “Sub-center ArcFace: Boosting face recognition by large-scale noisy web faces,” in *Proc. Eur. Conf. Comput. Vis. (ECCV)*, 2020, pp. 741–757.
- [21] G. Zoss, P. Chandran, E. Sifakis, M. Gross, P. Gotardo, and D. Bradley, “Production-ready face re-aging for visual effects,” *ACM Trans. Graph. (SIGGRAPH Asia)*, vol. 41, no. 6, pp. 1–12, 2022.
- [22] European Parliament and Council of the European Union, “Regulation (eu) 2016/679 (general data protection regulation),” *Official Journal of the European Union*, L119, 2016.