

Возраст-инвариантное сопоставление личности по «естественно заякоренным» постам соцсетей: naturally-supervised longitudinal-сигнал

Данил Ф. Вольхин и Иван С. Копылов

Аннотация—Кросс-возрастная верификация лиц — определение того, изображён ли на двух фотографиях, снятых с разрывом в годы, один и тот же человек — трудна: возраст сильно меняет внешность, а модели склонны опираться на возраст как на шорткат. Мы изучаем data-centric вопрос: можно ли получить супервизию для возрастной инвариантности без вручную размеченного longitudinal-датасета? Мы показываем, что мультифото-посты «тогда/сейчас», где один человек показан в разном возрасте, дают «естественно заякоренные» позитивные пары личности, и что дообучение слабого распознавателя на них учит переносимой возрастной инвариантности. Наша супервизия не требует ручных меток (нет человеческой разметки личности или возраста), хотя конвейер использует LLM-парсер подписей и кластеризацию эмбеддингов; поэтому мы называем её naturally supervised и аудлируем эти компоненты. На внешнем кросс-возрастном бенчмарке FG-NET дообучение намеренно слабого обучаемого backbone поднимает large-gap (≥ 25 лет) ROC-AUC с 0.736 до 0.848 ($+0.112 \pm 0.001$ по трём сидам) ценой лишь -0.019 на LFW; AgeDB-30 и CALFW подтверждают. Эффект (а) превосходит синтетическое старение даже с настоящей генеративной aging-моделью; (б) воспроизводится на трёх loss-семействах, двух архитектурах, двух независимых источниках одной платформы и двух обучающих целях — наш простой pair-contrastive objective совпадает с канонической ArcFace-классификацией на ключевой внешней метрике (0.848 против 0.851). Таким образом, результат — это целевая large-gap-устойчивость, а не равномерный прирост верификации; мы делаем ограниченное утверждение: в рамках этого протокола и среди рассмотренных целей вклад naturally-supervised данных в large-gap-прирост больше, чем выбор между loss-семействами. Прирост механистически связан со снятием возрастного шортката: точность frozen-моделей падает почти к случайности при age-matched негативах, а наши пары её восстанавливают. Метод данные-эффективен ($\approx 96\%$ прироста на 10% личностей). В аудите по кажущимся полу/возрасту ни одна страта не ухудшается, а наибольший значимый прирост — у младшей группы (0–17), где базовая модель слабее всего. Дополнительно мы даём калиброванную $P(\text{same} \mid \text{cosine}, \text{age-gap})$ и конвейер чистки, главная находка которого — около половины сырых «позитивов» были near-duplicate кадрами, завышавшими внутренние метрики.

Index Terms—Кросс-возрастное распознавание лиц, возраст-инвариантное представление, naturally/weakly-

supervised личность, курирование датасета, shortcut learning, справедливость, калибровка.

I. Введение

КРОСС-ВОЗРАСТНАЯ верификация важна для архивного поиска, восстановления доступа и авторизованного поиска пропавших людей. Сложность не в том, чтобы различить случайных людей, а в том, чтобы отличить одного и того же человека сквозь возраст от разных людей схожего возраста и внешности. Разметка longitudinal-пар личности (один человек на протяжении многих лет) дорога и редка, что является узким местом supervised-подходов; свежие работы продолжают отмечать слабую кросс-датасетную генерализацию и дефицит качественных longitudinal-данных.

Гипотеза. Мультифото-пост «тогда/сейчас» с одним человеком в разном возрасте даёт $\binom{n}{2}$ позитивных пар личности без ручной разметки; подпись с возрастами добавляет age-anchor. Это масштабируемый naturally-supervised сигнал кросс-возрастной идентичности, и дообучение слабого распознавателя на нём должно переноситься на внешние бенчмарки.

Вклад (ограниченные claims). (1) Naturally-supervised (без ручных меток) longitudinal-сигнал, намайненный из соцпостов. (2) Строгий протокол атрибуции (один слабый обучаемый backbone, frozen против дообученного, внешняя оценка), изолирующий вклад данных от ёмкости сети. (3) Взаимоусиливающие контроли (loss-семейство, архитектура, источник, обучающая цель, real-vs-synthetic, диагностика шортката), обосновывающие ограниченный тезис: в этом протоколе и среди рассмотренных целей вклад данных в large-gap-прирост больше, чем выбор между loss-семействами. (4) Конвейер курирования с аудитом автоматических компонентов и находка, что сырой счёт позитивов раздут примерно вдвое near-duplicate кадрами. (5) Прикладная калибровка и аудит по кажущимся стратам с доверительными интервалами.

Мы подчёркиваем, что новизна data-centric, а не архитектурная — новый источник супервизии — и оценивать её следует по этой оси.

II. Связанные работы и позиционирование

Три семейства-предшественника. Дискриминативная возраст-инвариантная FR на размеченных данных:

Рукопись подготовлена в 2026 г.

Д. Ф. Вольхин (автор) и И. С. Копылов (научный руководитель) — Национальный исследовательский университет «Высшая школа экономики» (НИУ ВШЭ), Москва, Россия (e-mail: deneal123@mail.ru; ORCID: 0009-0000-8108-8814).

Код, конфигурации и обезличенный протокол бенчмарка доступны по адресу <https://github.com/deneal123/ChildVSAdult>.

OE-CNN (ортогональное разложение признаков) [1], DAL (decorrelated adversarial learning) [2] и MTLFace (multi-task: распознавание, синтез возраста и attention-decomposition) [3] достигают высокой точности, но обучаются на данных с ручными метками личности и возраста (CACD [4], MORPH [5], AgeDB [6], FG-NET [7]). Cross-age contrastive с синтетикой: CACCon [8] добавляет синтезированный cross-age семпл и triplet-loss; OrdCon [9] использует order-enhanced contrastive. Синтетическое старение: систематические оценки показывают лишь частичную пользу [10]. Общий self-supervised FR (SimCLR-аугментации [11]) не имеет identity-якорей во времени. Мы майним структуру «один пост = один человек в разном возрасте» как бесплатный генератор позитивов. Таблица I позиционирует нас относительно этих методов.

Мы отчитываемся на канонических кросс-возрастных бенчмарках этих методов (AgeDB-30, CALFW [12], FG-NET; CALFW специально создан как более жёсткий age-gapped LFW [13]). Цель — не побить абсолютный SOTA (мы используем слабый backbone для чистой атрибуции), а измерить величину и переносимость выигрыша от naturally-supervised источника; разд. V-F обучает каноническую SOTA-цель на наших данных напрямую.

III. Данные: «естественно заякоренные» longitudinal-пары

Источник. Две публичные «тогда/сейчас» мультифото-стены VK (одна платформа, русскоязычный контекст). Лица детектируются и выравниваются по 5-точечному ArcFace-шаблону (InsightFace RetinaFace [14], buffalo_l). Usable-лицо проходит пороги det-score, минимального размера, размытия и единственного целевого лица (разд. IX). Сырой намайненный корпус сведён в Таблице II (слева).

A. Извлечение возраста

Подписи парсятся регулярными выражениями (русские паттерны плюс слэш-формат «6/18/21», один возраст на фото) и LLM (GigaChat). LLM-аудит всех 33 697 мультифото-подписей (Таблица III) показал, что LLM существенно точнее regex — не принимает календарные годы или разрывы за возраст и восстанавливает второй возраст — расходясь на 27.2% постов, в основном в пользу LLM.

B. Личности и leakage-safe сплит

Наивное «один пост = одна личность» недосчитывает: человек повторяется в постах. Мы кластеризуем пост-группы в личности по близости эмбедингов ($\cos \geq 0.85$), получая 21 848 личностей из 27 487 пост-групп ($\approx 20\%$ повторов), и делим по человеку (не по посту). Ручная проверка high-cosine пар показала, что косинус не разделяет look-alike от same-person в зоне 0.55–0.8, поэтому порог слияния намеренно консервативен (0.85).

C. Аудит автоматической супервизии

Поскольку сигнал naturally (не человечески) supervised, автоматические компоненты — потенциальный скрытый шум меток и аудируются: согласие LLM-vs-regex по возрасту (Таблица III); ручная проверка идентичности high-cosine пар; и gender-consistency внутри личности как бесплатный детектор шума (2 919 мультифото-групп с согласием < 0.6 помечают вероятный мульти-человек). Отдельный human-audited subset (точность извлечения возраста, точность group-integrity, error-matrix, согласие человек–LLM, κ) сопровождает релиз.

D. Конвейер курирования и его главная находка

Три шага: (i) метаданные кажущихся пола/возраста (оценщик) на лицо, агрегированные по личности — корпус на 76.7% apparent-female / 23.3% apparent-male; (ii) LLM-валидация целостности групп (Таблица IV) — кластеризация по личности уже развела большинство мульти-человек постов, поэтому шумными помечены лишь 421 person-группа; (iii) near-duplicate дедуп внутри каждой личности ($\cos \geq 0.97$), убивающий 8 190 лиц ($\approx 17\%$).

Ключевая находка. Поскольку позитивы квадратичны по числу лиц в группе, удаление near-duplicate обрушило позитивы $65\,897 \rightarrow 31\,865$ (–52%): около половины сырых «позитивов» были дубликатами кадров (одна съёмка, серия или репост), завышавшими внутреннюю метрику. После курирования frozen-базлайн на внутреннем тесте честно падает (our.overall $0.856 \rightarrow 0.836$; our.25+ $0.705 \rightarrow 0.640$), вскрывая более трудный и честный бенчмарк. Внешние бенчмарки не затронуты. Это переносимый урок для майнинга longitudinal-пар из соцсетей.

Устойчивость к порогу. Сокращение на –52% — не артефакт порога 0.97. Повторный near-dup дедуп на до-курационных группах при косинусе 0.93–0.99 (Таблица V) оставляет 31.3k–32.4k позитивов на 0.93–0.97 (стабильно $\approx 52\%$) и плавно слабеет лишь на очень строгом 0.99 (–41%): near-duplicate-ы — это почти идентичные кадры ($\cos \approx 1$), поэтому находка не зависит от точного порога.

E. Карточка датасета (кратко)

Provenance, права и governance хранятся по элементу (источник, URL, дата сбора, статус лицензии/consent, разрешённое использование, политика хранения, статус удаления, статус ревью). Сбор: публичные стены VK. Назначение: исследование consent-based кросс-возрастного сопоставления. Вне scope: массовая идентификация, слежка, деанонимизация. Несовершеннолетние: режим child $\leftrightarrow$ adult в score только при явных правовых/этических рамках; статус ревью отслеживается по элементу, удаление по запросу поддержано. Полная карточка [15] сопровождает релиз.

Таблица I
Позиционирование относительно предшественников.

Работа	Супервизия	Механизм	Наше отличие
OE-CNN (2018) [1]	размеч. id+age	ортогональное разложение	label-free источник, не decomposition
DAL (2019) [2]	размеч. id+age	adversarial id/age факторизация	mined-пары + проще objective
MTLFace (2021) [3]	размеч. id+age	распознавание + синтез (multi-task)	проще конвейер; новый источник супервизии
CACon (2023) [8]	semi-sup. + синтетика	contrastive на синтезе	реальные mined-пары > синтетика (разд. V-B)
Synthetic Ageing (2024) [10]	синтетика	обучение на состаренных	у нас реальный mining как тезис
OrdCon (2025) [9]	age-ordered contrastive	order-enhanced признаки	майним естественные пары, без явного порядка

Таблица II
Масштаб датасета (сырой mining) и после курирования (разд. III-D).

Стадия	Посты	Фото	Usable-лица	Личности (группы)	Позитивные пары
Сырой mining (2 стены)	44 609	84 147	49 606	21 848	65 897
После курирования	—	—	40 586	21 427	31 865

Таблица III
Аудит извлечения возраста: LLM против regex (33 697 постов с подписью).

Категория	<i>n</i>	Доля
Согласие (те же возраста или оба пусты)	24 531	72.8%
LLM нашёл (regex пропустил)	3 656	10.8%
Расхождение возрастов	4 658	13.8%
LLM пусто (regex нашёл)	852	2.5%

Таблица IV
LLM-классификация целостности групп (33 697 постов).

Категория	<i>n</i>	Доля
Single (один человек в разном возрасте)	31 275	92.8%
Multi-person (разные люди)	2 034	6.0%
Unknown	336	1.0%
Meme / collage	52	0.2%

Таблица V
Чувствительность к порогу дедуна: только удаление near-duplicate, на до-курационных группах (отдельный prune целостности убирает ещё ≈500 позитивов до headline-значения 31 865). Стабильно на 0.93–0.97.

Порог cos	Near-dup лиц	Позитивов	Сокращение
0.93	8 653	31 304	−52.5%
0.95	8 564	31 611	−52.0%
0.97 (исп.)	8 304	32 360	−50.9%
0.99	6 274	38 565	−41.5%

IV. Метод, протокол и статистика

Протокол атрибуции. Сравнивать adapter поверх замороженного сильного ArcFace с frozen-ArcFace некорректно (adapter лишь деформирует почти идеальные

эмбединги). Вместо этого мы используем один слабый обучаемый backbone (FaceNet InceptionResnetV1 [16], CASIA-WebFace) и сравниваем (а) frozen → метрика бенчмарка против (б) мягкого дообучения головы на наших парах → метрика бенчмарка. Обучение использует margin contrastive loss на выровненных кропах. Оценка — на внешних бенчмарках (LFW, AgeDB-30, CALFW, FG-NET) для чистой атрибуции переноса; внутренний тест (our.*) — вторичная диагностика. Сила backbone варьируется (разд. V-C). Дизайн жертвует абсолютным качеством ради причинной атрибуции.

Backbone. FaceNet (слабый); ArcFace iResNet-50 [17] (CASIA-FaceV5; слабый, другая архитектура); AdaFace IR-50/IR-101 [18] (WebFace; сильный; чистый депт-контроль); ArcFace iResNet-100 (сильный).

Бенчмарки и метрики. LFW (10-fold accuracy), AgeDB-30 и CALFW (выровненные пары; ROC-AUC и 10-fold accuracy), FG-NET (ROC-AUC overall и на large-gap ≥25 лет). Мы намеренно не опираем headline только на FG-NET (мал, стар, частичное покрытие детектором); AgeDB-30 и CALFW подтверждают. Различаем threshold-free метрики (ROC-AUC) и threshold-based (accuracy, TAR@FAR).

Статистика. Наш первичный эндпойнт — FG-NET large-gap (≥25 лет) ROC-AUC, с нулевой гипотезой, что дообучение на намайненных парах не улучшает его относительно frozen-базлайна (прирост ≤ 0); AgeDB-30, CALFW и внутренний кросс-возрастной тест — вторичные эндпойнты, а easy-LFW accuracy отслеживается как контроль забывания. Headline-прирост — среднее ± std по трём сидам (сид-разброс отражает стохастичность обучения, не полную неопределённость оценки). Аудит справедливости использует парный перцентильный bootstrap (1000 ресэмплингов, ресэмплинг пар с пересчётом обеих моделей на одной выборке) для прироста, учитывая корреляцию frozen/tuned. Таблица VII при-

водит bootstrap-CI, EER и TAR@FAR для ключевых сравнений (внутренний тест дополнительно использует identity-level bootstrap с ресэмплингом личностей), а поправка Holm применяется по стратифицированным тестам справедливости.

Очищенный датасет. Все headline-эксперименты — на очищенных данных разд. III-D: 21 427 групп личностей, 40 586 лиц, 31 865 позитивов; сплит train 22 179 / val 4 579 / test 5 107 со сбалансированными негативами по сплитам.

V. Результаты

A. Главный эффект и self-supervised ablation

Слабый FaceNet, мягко дообученный на наших парах, поднимает FG-NET large-gap ROC-AUC $0.736 \rightarrow 0.848$ ($+0.112 \pm 0.001$), тогда как easy-LFW падает лишь на -0.019 , а AgeDB-30/CALFW почти не двигаются (Таблица VI). Ablation изолирует источник: same-post пары не используют ручных меток — ни личности, ни возраста — и дают почти весь прирост; явные age-anchor добавляют лишь $+0.009$ на 25+ (pre-clean ablation). Поэтому метод по сути self-supervised по личности, а возрастная супервизия — тонкая надстройка.

Прирост статистически устойчив ($\text{std} \leq 0.003$) и переживает чистку; внутренний кросс-возрастной прирост даже растёт на более трудном очищенном тесте (our.25+ $+0.195$), т.к. чистка опускает frozen до 0.640, а +pairs восстанавливает до 0.835.

Bootstrap-доверительные интервалы (сид 42) подтверждают первичный эндпойнт: FG-NET large-gap растёт с 0.736 [0.70, 0.78] до 0.848 [0.82, 0.88] с непересекающимися 95% CI; equal-error rate почти вдвое меньше ($0.335 \rightarrow 0.219$), а TAR@FAR=1% почти вдвое больше ($0.21 \rightarrow 0.39$). На внутреннем 25+ тесте прирост сохраняется при более консервативном identity-level bootstrap (ресэмплинг личностей, не пар): +pairs 0.838 [0.80, 0.88] против frozen 0.640 [0.59, 0.69] — интервал шире pair-level, что ожидаемо, когда пары делят личности. Операционные точки и интервалы по всем бенчмаркам — в Таблице VII.

B. Реальные пары превосходят синтетическое старение

Замена реальных позитивов синтетически состаренными — доменный прокси и настоящая re-aging-сеть (FRAN [19]) — не просто не помогает, а активно вредит на очищенных данных: FRAN даёт FG-NET large-gap 0.727 (ниже frozen 0.736), а our.25+ рушится до 0.549 (ниже frozen 0.640), тогда как реальные пары дают $+0.112$ / $+0.198$ (Таблица VIII). Identity-preserving старение учит текстурным артефактам, а не реальной longitudinal-вариации (поза, камера, эпоха). (Кропы 112 px ограничивают fidelity FRAN, рассчитанного на ≈ 1024 px.)

C. Кривая headroom и режим сильных backbone

Прирост воспроизводится на FaceNet, ArcFace iResNet и AdaFace IR-50/IR-101 (три loss-семейства, две




Рис. 1. Кривая headroom: прирост от +pairs на FG-NET large-gap монотонно убывает с усилением frozen-backbone, пересекая ноль для сильных насыщенных моделей.

архитектуры) и монотонно убывает с силой frozen (Таблица IX, Рис. 1); чистый депт-контроль (AdaFace IR-50 $\rightarrow$ IR-101) это подтверждает. Прямо заявляем: сильные насыщенные backbone не растут и слегка забывают при дообучении; мягкий learning rate ($1e-5$) примерно вдвое уменьшает забывание, но не превращает его в прирост. Вклад специфичен для слабых/средних backbone с кросс-возрастным запасом — ограничение, которое мы не скрываем (разд. VII).

D. Закон масштабирования данных

Варьируя долю обучающих личностей (val/test фиксированы), прирост насыщается очень рано: $\approx 96\%$ полного прироста FG-NET large-gap достигается уже на 10% личностей (≈ 1500), с плато от 25% (Таблица X, Рис. 2); небольшой провал на полном объёме ($0.50 \rightarrow 1.00$) — в пределах сид-разброса: кривая плоская, не монотонная, после $\approx 10\%$. Сигнал данные-эффективен; дальнейший рост требует более трудных данных (большие разрывы, hard-позитивы), а не просто большего объёма.

E. Механизм — возрастной шорткат

При age-matched негативах (тот же возрастной бакет, разные люди) точность frozen на внутреннем 25+ тесте падает с 0.640 до 0.517 (почти к случайности, 0.5), а реальные пары восстанавливают её до 0.838 (Рис. 3) — прямое доказательство, что frozen-модели различают кросс-возрастные пары во многом по возрасту, а наши пары учат различать по личности. Линейный probe уточняет это представлено (Таблица XI): кажущийся возраст остаётся хорошо декодируемым из identity-эмбединга у всех моделей ($\approx 0.63-0.65$ bal-acc $\gg 0.25$ случайность) и меняется лишь слегка, тогда как identity-AUC растёт — то есть метод учит инвариантную метрику (косинус перестаёт опираться на возраст-

Таблица VI

Главный результат: слабый FaceNet frozen против +pairs, три сйда, очищенные данные. Прирост до чистки — для сравнения.

Метрика	Frozen	+pairs (сред. $\pm$ std)	Прирост	(до чистки)
FG-NET large-gap	0.7361	0.8484 $\pm$ 0.0007	+0.1124	+0.1215
FG-NET ROC	0.8955	0.9230 $\pm$ 0.0006	+0.0275	+0.0277
our.25+ (внутр.)	0.6403	0.8348 $\pm$ 0.0027	+0.1946	+0.1677
our.overall (внутр.)	0.8363	0.9163 $\pm$ 0.0009	+0.0801	+0.0764
LFW accuracy	0.9688	0.9503 $\pm$ 0.0031	−0.0185	−0.0283
AgeDB-30 ROC	0.9530	0.9462 $\pm$ 0.0013	−0.0068	−0.0155
CALFW ROC	0.9482	0.9489 $\pm$ 0.0014	+0.0007	−0.0030

Таблица VII

Операционные точки и 95% bootstrap-CI (FaceNet frozen vs. +pairs, сид 42). Все значения — ROC-AUC; LFW показан как ROC-AUC для согласованности (его 10-fold accuracy — в Таблице VI). Внешние CI — pair-level; внутренний тест дополнительно использует identity-level bootstrap (см. текст).

Бенчмарк	Frozen AUC [95% CI]	+pairs AUC [95% CI]	EER (fr. $\rightarrow$ +p.)	TAR@1%	TAR@0.1%
FG-NET large-gap	0.736 [0.70, 0.78]	0.848 [0.82, 0.88]	0.335 $\rightarrow$ 0.219	0.209 $\rightarrow$ 0.386	0.074 $\rightarrow$ 0.154
FG-NET overall	0.896 [0.89, 0.90]	0.922 [0.92, 0.93]	0.186 $\rightarrow$ 0.151	0.502 $\rightarrow$ 0.562	0.315 $\rightarrow$ 0.308
AgeDB-30	0.953 [0.95, 0.96]	0.945 [0.94, 0.95]	0.115 $\rightarrow$ 0.126	0.525 $\rightarrow$ 0.510	0.285 $\rightarrow$ 0.309
CALFW	0.948 [0.94, 0.95]	0.948 [0.94, 0.95]	0.116 $\rightarrow$ 0.117	0.580 $\rightarrow$ 0.624	0.213 $\rightarrow$ 0.320
LFW (AUC)	0.994 [0.99, 1.00]	0.987 [0.98, 0.99]	0.032 $\rightarrow$ 0.052	0.940 $\rightarrow$ 0.869	0.858 $\rightarrow$ 0.575

Таблица VIII

Реальные против синтетических позитивов (FaceNet, очищенные данные).

Метрика	Frozen	+реал.	+синт. (прокси)	+синт. (FRAN)
FG-NET large-gap	0.736	0.848	0.761	0.727
our.25+	0.640	0.838	0.594	0.549

Таблица IX

Headroom: FG-NET large-gap по силе backbone (очищенные данные, $\lg 3e-5$).

Backbone (сила)	Frozen	+pairs	Δ large-gap	Δ our.25+
FaceNet (слабый)	0.736	0.848	+0.112	+0.198
ArcFace r50 (слабый, др. арх.)	0.764	0.805	+0.041	+0.133
AdaFace IR-50 (сильный)	0.917	0.924	+0.007	+0.004
ArcFace r100 (сильный)	0.954	0.915	−0.039	−0.002
AdaFace IR-101 (сильный)	0.957	0.931	−0.026	−0.006

Таблица X

Закон масштабирования (FaceNet, очищенные; val/test фиксированы).

Доля train	# личностей	FG-NET large-gap	our.25+
frozen	0	0.736	0.640
0.10	$\approx 1\,500$	0.845	0.814
0.25	$\approx 3\,750$	0.853	0.842
0.50	$\approx 7\,499$	0.864	0.848
1.00	$\approx 14\,998$	0.848	0.838

Таблица XI

Линейный probe age-leakage (очищенные данные; случайность = 0.25).

Модель	Age-probe bal. acc. $\downarrow$	Identity ROC-AUC $\uparrow$
frozen	0.651 $\pm$ 0.019	0.836
+pairs	0.629 $\pm$ 0.012	0.916
+pairs+disentangle	0.632 $\pm$ 0.017	0.918

F. Сравнение objective: обучение SOTA-цели на наших данных

Мы обучаем каноническую цель современной FR — ArcFace-margin классификацию личности [17] (ядро OE-CNN/MTLFace) — на наших naturally-supervised личностях (9204 класса), тот же слабый backbone, score и протокол. На ключевой внешней метрике кон-

ную ось), а не age-free представление; явный adversarial disentanglement не снижает leakage дополнительно.




Рис. 2. Закон масштабирования: внешний (FG-NET large-gap) и внутренний (our.25+) ROC-AUC против числа обучающих личностей (лог-шкала). Около 96% прироста достигается на 10% личностей; пунктир — frozen-базлайны.




Рис. 3. Возрастной шорткат. На identity-only тесте (age-matched негативы) frozen падает почти к случайности; дообучение на наших парах восстанавливает различие по личности.

трастив и ArcFace совпадают (Таблица XII, Рис. 4). Делаем ограниченный вывод: в этом протоколе и среди рассмотренных целей вклад источника данных доминирует над выбором objective — а не «метод не важен вообще». ArcFace дополнительно забывает меньше на easy-бенчмарках — практическая рекомендация.

Г. Аудит по кажущимся стратам

Стратифицируя по кажущимся полу/возрасту якоря пары (оценка, не самоидентификация), ни одна страта не ухудшается, и каждый прирост значим (95% парный bootstrap-CI > 0; Таблица XIII, Рис. 5). Максимальный прирост — у младшей группы 0–17 (frozen 0.750 → +pairs 0.880, +0.130, CI не пересекается со взрослыми полосами) — метод усиливает там, где базовая модель слабее всего (режим child↔adult), сужая кажущийся демографический разрыв. Мы намеренно избегаем сло-




Рис. 4. Сравнение objective: pair-contrastive и каноническая ArcFace-классификация совпадают на кросс-возрастном переносе; ArcFace чуть меньше забывает на easy-бенчмарках.




Рис. 5. Аудит по кажущимся стратам: frozen против +pairs ROC-AUC по стратам кажущихся пола/возраста. Все страты улучшаются; максимальный прирост — у младшей группы (0–17), где frozen слабее всего. Усы — 95% парный bootstrap-CI прироста, n — число позитивных пар на страту (у разреженной страты 45+, $n=153$, интервал соответственно широк).

ва «справедлив» как решённого свойства: источник перекошен в женскую сторону (76.7%), атрибуты кажущиеся (не этничность и не юридические категории), а 45+ разрежена.

Н. Перенос между источниками

Обучение на одном сообществе и тест на held-out другом переносит прирост: внешний FG-NET large-gap +0.113 (против +0.112 within-source — практически идентично) и внутренний +0.092 на held-out сообществе. Мы формулируем это как перенос между двумя

Таблица XII
Сравнение objective (FaceNet, очищенные данные).

Метрика	Frozen	+pairs (контрастив)	+ArcFace (класс.)
FG-NET large-gap	0.736	0.848	0.851
our.25+	0.640	0.838	0.868
LFW accuracy	0.969	0.946	0.952
AgeDB-30 ROC	0.953	0.945	0.947

Таблица XIII
Кажущиеся страты пол/возраст (FaceNet, очищенные; 95% парный bootstrap-CI прироста).

Страта	n_{pos}	Frozen	+pairs	Прирост	95% CI
overall	5 107	0.836	0.916	+0.080	[+0.075, +0.086]
apparent F	3 790	0.840	0.923	+0.084	[+0.077, +0.090]
apparent M	1 317	0.838	0.897	+0.059	[+0.048, +0.071]
возраст 0–17	1 123	0.750	0.880	+0.130	[+0.113, +0.146]
возраст 18–29	3 159	0.872	0.936	+0.064	[+0.058, +0.069]
возраст 30–44	672	0.822	0.893	+0.070	[+0.054, +0.087]
возраст 45+	153	0.859	0.893	+0.034	[+0.004, +0.064]

независимыми источниками внутри одного платформенного домена, а не platform-agnostic или web-scale генерализацию.

I. Калибровка

Сырой косинус (Platt) плохо калиброван по бинам разрыва — переуверен на 15–25 лет (ECE 0.052); калибратор $P(\text{same} \mid \text{cosine}, \text{age-gap})$ чинит каждый бин (15–25 $\rightarrow$ 0.017) и улучшает общий Brier (0.035 $\rightarrow$ 0.029) — пригодная age-aware вероятность того же человека.

J. Disentanglement

Явное удаление возраста (gradient reversal + age-голова, в стиле MTLFace) даёт малый, но устойчивый кросс-возрастной прирост (+0.0055 FG-NET large-gap, +0.0145 our.25+ над +pairs) без вреда easy-бенчмаркам (даже чуть выше +pairs: LFW 0.951 против 0.946); в абсолюте его large-gap ($\approx$ 0.853) на уровне ArcFace-цели из разд. V-F (0.851), что согласуется с тем, что потолок cross-age задают данные — а не objective или disentangle-надстройка. Вместе с разд. V-E это показывает, что явная age-супервизия — тонкая надстройка над данными.

K. Майнинг hard-негативов

Добавление самых трудных кросс-личностных негативов в дообучение — top-5 наиболее похожих по косинусу лиц других людей на якорь (косинус в «трудной» полосе, исключая near-duplicate/uncertain диапазон) — дополнительно обостряет кросс-возрастное различие: FG-NET large-gap растёт до 0.866 (с 0.848 при случайных негативах), но easy-бенчмарки забываются сильнее (LFW 0.969 $\rightarrow$ 0.934 против 0.950 у +pairs; AgeDB-30 и CALFW аналогично; Таблица XIV). То есть hard-негативы меняют калибровку лёгких пар на кросс-возрастное разделение — полезно для cross-age retrieval,

Таблица XIV
Майнинг hard-негативов (FaceNet, очищенные данные; внешние бенчмарки, один прогон).

Метрика	Frozen	+pairs	+pairs+hard-neg
FG-NET large-gap	0.736	0.848	0.866
FG-NET ROC	0.896	0.923	0.927
LFW accuracy	0.969	0.950	0.934
AgeDB-30 ROC	0.953	0.946	0.931
CALFW ROC	0.948	0.949	0.934

не для общего верификатора. (Один прогон; внутренний hard-neg тест у frozen почти случаен по построению и несопоставим со стандартным внутренним тестом.)

VI. Обсуждение

Вклад — масштабируемый naturally-supervised источник longitudinal-супервизии и доказательство того, что он учит переносимой возрастной инвариантности, которую не заменяет синтетика и не объясняет явная age-супервизия. Взаимоусиливающие контроли — loss-семейство, архитектура, источник, обучающая цель — сходятся к ограниченному выводу: в этом протоколе данные доминируют над objective среди рассмотренных вариантов. Диагностика шортката даёт чистую identity-only метрику и объясняет механизм; находка чистки (половина сырых позитивов — дубликаты) сама по себе является методологическим уроком. Это data-centric вклад, не архитектурный; ряд claims ограничен нашей двухисточниковой, одноплатформенной, кажущейся-атрибутой постановкой.

VII. Ограничения

- Зависимость от backbone: прирост сосредоточен у слабых/средних backbone; сильные насыщенные не

растут и слегка забывают (мягкий lr смягчает, но не обращает).

- Внешняя валидность: два сообщества VK, одна платформа, один язык/культурный контекст; перекос в женскую сторону (76.7%); разреженность на apparent 45+. Перенос показан между этими источниками и на стандартные бенчмарки, а не platform-agnostic генерализация.
- Только кажущиеся атрибуты в аудите справедливости (оценка, не самоидентификация пола/этничности).
- Naturally-supervised, не строго label-free: LLM парсит возраст и валидирует целостность групп; кластеризация формирует личности — аудировается (разд. III-C), но остаётся источником скрытого шума.
- Статистика: сид-разброс, парный bootstrap (справедливость) и CI / EER / TAR@FAR по бенчмаркам (Таблица VII, включая identity-level bootstrap) приведены в тексте; DeLong-тесты и полная поправка на множественные сравнения по каждой ячейке — в release-supplement.
- Масштаб и возраст бенчмарков: мы оцениваем на стандартном для области наборе кросс-возрастных бенчмарков — AgeDB-30 и CALFW (по 6 000 пар) и FG-NET для явного подмножества ≥ 25 лет — тех же, что используют OE-CNN/DAL/MTLFace, что обеспечивает сопоставимость, но наследует их ограниченный масштаб и возраст (FG-NET особенно мал, с частичным покрытием детектором, поэтому headline не опирается только на него). Наш очищенный внутренний тест (5 107 кросс-возрастных позитивов с контролируемыми негативами) — крупный современный дополнительный; большой независимый не-VK longitudinal-набор и специализированный child $\leftrightarrow$ adult бенчмарк остаются приоритетом дальнейшей работы.
- Полные SOTA-конвейеры не воспроизведены целиком: по замыслу мы обучаем общее ядро современной AIFR — ArcFace-цель с угловым margin — в нашем протоколе со слабым backbone ради чистой атрибуции, а не сравнения в лидерборде. Разд. V-F показывает, что эта цель совпадает с нашим контрастивом на ключевой внешней метрике, т.е. выигрыш определяется не objective; опущенные метод-специфичные надстройки (генеративная ветвь синтеза возраста MTLFace, ортогональное разложение подпространств OE-CNN) уточняют это общее ядро и ортогональны нашему утверждению об источнике супервизии. Закрывает ли полный SOTA-конвейер на naturally-supervised данных остаточный абсолютный разрыв — чётко очерченное продолжение.

VIII. Этика, правовая основа и data governance

Это чувствительное биометрическое исследование; мы рассматриваем governance как полноценный компонент, а не дисклеймер. Разрешённое использование ограничено controlled / consent-based / human-reviewed

приложениями (архивы и семейные фото с очищенными правами, авторизованный гуманитарный поиск, восстановление доступа); система выдаёт кандидатов для проверки человеком, а не автоматическое решение. Запрещено: массовая идентификация, деанонимизация, слежка и любая обработка данных несовершеннолетних без правовой основы.

A. Этическое одобрение и правовая основа

Этическое одобрение. Исследование рассмотрено [название этического комитета] Национального исследовательского университета «Высшая школа экономики»; оно было [одобрено по протоколу № XXXX / признано освобождённым] [дата]. Согласие. Поскольку данные взяты из публичных постов без реальной возможности связаться с субъектами, индивидуальное информированное согласие на участие и на публикацию не получалось; мы опираемся на научно-исследовательскую основу и меры обезличивания разд. VIII-B.

Замечание (удалить перед подачей). IEEE T-BIOM открывает без рецензирования исследование на людях без заявления об этическом одобрении (или документированном освобождении). Получите одобрение этического комитета НИУ ВШЭ или письменное освобождение, затем заполните красным название комитета, протокол/освобождение и дату выше. Формулировку «без индивидуального согласия» следует согласовать с этим комитетом.

Данные собраны с публичных «тогда/сейчас» стен сообществ через официальный API платформы. Подчёркиваем: официальный доступ к API и добровольная публикация сами по себе НЕ дают права на биометрическую обработку. По 152-ФЗ поправка 2020 г. (519-ФЗ) заменила «общедоступные» данные на «данные, разрешённые субъектом для распространения» (требуется отдельное согласие), а ст. 11 требует письменного согласия на биометрию, используемую для установления личности; по GDPR [20] лицо, обработанное для уникальной идентификации, — спецкатегория (ст. 9), где исключение «manifestly made public» трактуется узко (ср. санкции против Clearview AI). Явного/письменного согласия у нас нет. Мы опираемся на научно-исследовательскую основу (GDPR ст. 6(1)(f) и 9(2)(j) с safeguards ст. 89; аналогичная research-обработка по 152-ФЗ) и компенсируем мерами минимизации, не-распространения и обезличивания ниже. Мы прозрачно фиксируем этот пробел, а не заявляем полное соответствие, и рекомендуем этическую экспертизу организации и консультацию юриста по защите данных до любого развёртывания.

B. Обезличивание и политика релиза

Мы не публикуем сырые изображения лиц и сырые посты. Публичный релиз содержит только код, веса обученной модели, производные эмбединги, псевдонимизированный бенчмарк-протокол и агрегатную статистику. Все идентификаторы платформы (owner/photo/post ID) заменяются солёными хешами; подписи/комментарии (которые могут содержать

имена) исключаются; хранятся только возраст-бакеты и псевдонимный person ID. Сырые кропы хранятся только локально под политикой хранения. Доступ к неагрегатным производным данным предоставляется квалифицированным исследователям по Data Use Agreement (только research; запрет реидентификации; запрет коммерческого/слежечного использования). Фигуры статьи не содержат идентифицируемых лиц (только ко агрегатные графики).

C. DPIA и минимизация

Поскольку обработка биометрическая и масштабная, проводится оценка воздействия на защиту данных (DPIA), сопровождающая релиз (ключевые риски: реидентификация, function creep, несовершеннолетние; меры — как в разд. VIII-B и разд. VIII-D). Минимизация данных применяется сквозно (храним кроп лица + возраст + псевдонимный ID, не имена и не соцграф).

D. Несовершеннолетние

Режим child↔adult неизбежно включает изображения несовершеннолетних, чьи данные защищены строже всего (152-ФЗ; GDPR ст. 8). Элементы детского возраста (помеченные по кажущемуся возрасту) исключаются из любого релиза при отсутствии явных правовых рамок и проверяемого согласия законного представителя и используются только для агрегатного, не-распространяемого анализа.

E. Права субъектов

Предоставлены публичный контакт и процедура takedown / удаления по запросу; удаление распространяется на производные артефакты через поле статуса удаления по элементу. Где права неясны, элемент удерживается. Полная карточка датасета [15] и DPIA сопровождают релиз.

IX. Воспроизводимость

Мы публикуем скрипты и конфигурации. Ключевые детали: критерии usable-лица (det-score, минимальный размер, размытие по Лапласиану, единственное целевое лицо по IoU); детектор/выравнивание (InsightFace buffalo_l RetinaFace, 5-точечный ArcFace norm_crop, 112 px; вход FaceNet 160 px); эмбединги (ArcFace w600k_r50) для кластеризации/дедупа; кластеризация личности (union-find, $\cos \geq 0.85$); дедуп (внутри личности union-find, $\cos \geq 0.97$); LLM (GigaChat; полные версионированные системные промпты для извлечения возраста и валидации групп; concurrency 10; кэш, режюмируемо); сплит (по человеку, 70/15/15, сбалансированные негативы по сплитам, seed 42); сэмплинг негативов (кросс-личность случайно + age-matched вариант); обучение (margin contrastive, head scope, lr $3e-5$ для слабых / $1e-5$ для сильных; ArcFace-голова $m=0.5$, $s=32$, lr $1e-3$; ранняя остановка по внутреннему

val-AUC; сиды 42/1/2); метрики (чистый NumPy ROC-AUC через Mann–Whitney, EER, TAR@FAR; 10-fold для выровненных пар).

Вычисления. Всё исследование выполняется на одном ноутбуке: одна NVIDIA RTX 3060 Laptop GPU (6 ГБ), AMD Ryzen 7 5800H (8 ядер / 16 потоков) и 16 ГБ RAM под Windows 11; программный стек — Python 3.12, PyTorch 2.12 (CUDA 13.2, cuDNN 9.2), InsightFace 1.0 / ONNX Runtime 1.26 для детекции и эмбедингов, scikit-learn 1.9 / Matplotlib 3.11 для анализа и фигур. Протокол со слабым backbone удерживает всё исследование в пределах 6 ГБ GPU.

X. Заключение и дальнейшая работа

Мультифото-посты — дешёвый, масштабируемый naturally-supervised сигнал кросс-возрастной идентичности; дообучение слабого распознавателя на них даёт переносимый, кросс-источниковый, objective-устойчивый прирост, сосредоточенный на large-gap кросс-возрастном сопоставлении (с лишь незначительным забыванием на easy-бенчмарках), объяснимый снятием возрастного шортката, данные-эффективный и не ухудшающий ни одну кажущуюся демографическую страту. Дальнейшая работа: независимый не-VK и child↔adult-специфичный внешний набор; human-audited subset супервизии (с agreement человек–LLM); per-point multi-seed доверительные полосы для кривых scaling и headroom; полные DeLong-тесты и поправочная поправка на множественные сравнения; полные SOTA-надстройки; реальная aging-модель на нативном разрешении; и калиброванный демонстратор в рамках governance-ограничений разд. VIII.

Список литературы

- [1] Y. Wang, D. Gong, Z. Zhou, X. Ji, H. Wang, Z. Li, W. Liu, and T. Mei, "Orthogonal deep features decomposition for age-invariant face recognition," in Proc. Eur. Conf. Comput. Vis. (ECCV), 2018, pp. 738–753.
- [2] H. Wang, D. Gong, Z. Li, and W. Liu, "Decorrelated adversarial learning for age-invariant face recognition," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2019, pp. 3527–3536.
- [3] Z. Huang, J. Zhang, and H. Shan, "When age-invariant face recognition meets face age synthesis: A multi-task learning framework," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2021, pp. 7282–7291.
- [4] B.-C. Chen, C.-S. Chen, and W. H. Hsu, "Cross-age reference coding for age-invariant face recognition and retrieval," in Proc. Eur. Conf. Comput. Vis. (ECCV), 2014, pp. 768–783.
- [5] K. Ricanek and T. Tesafaye, "MORPH: A longitudinal image database of normal adult age-progression," in Proc. IEEE Int. Conf. Autom. Face Gesture Recognit. (FG), 2006, pp. 341–345.
- [6] S. Moschoglou, A. Papaioannou, C. Sagonas, J. Deng, I. Kotsia, and S. Zafeiriou, "AgeDB: The first manually collected, in-the-wild age database," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. Workshops (CVPRW), 2017, pp. 51–59.
- [7] G. Panis, A. Lanitis, N. Tsapatsoulis, and T. F. Cootes, "Overview of research on facial ageing using the FG-NET ageing database," IET Biometrics, vol. 5, no. 2, pp. 37–46, 2016.
- [8] H. Wang, V. Sanchez, and C.-T. Li, "Cross-age contrastive learning for age-invariant face recognition," in Proc. IEEE Int. Conf. Acoust. Speech Signal Process. (ICASSP), 2024, arXiv:2312.11195.

- [9] —, “From age estimation to age-invariant face recognition: Generalized age feature extraction using order-enhanced contrastive learning,” arXiv preprint arXiv:2501.01760, 2025.
- [10] W. Yao, M. A. Farooq, J. Lemley, and P. Corcoran, “Synthetic face ageing: Evaluation, analysis and facilitation of age-robust facial recognition algorithms,” arXiv preprint arXiv:2406.06932, 2024.
- [11] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, “A simple framework for contrastive learning of visual representations,” in Proc. Int. Conf. Mach. Learn. (ICML), 2020, pp. 1597–1607.
- [12] T. Zheng, W. Deng, and J. Hu, “Cross-age LFW: A database for studying cross-age face recognition in unconstrained environments,” arXiv:1708.08197, 2017.
- [13] G. B. Huang, M. Ramesh, T. Berg, and E. Learned-Miller, “Labeled faces in the wild: A database for studying face recognition in unconstrained environments,” Univ. of Massachusetts, Amherst, Tech. Rep. 07-49, 2007.
- [14] J. Deng, J. Guo, E. Ververas, I. Kotsia, and S. Zafeiriou, “RetinaFace: Single-shot multi-level face localisation in the wild,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2020, pp. 5203–5212.
- [15] T. Gebru, J. Morgenstern, B. Vecchione, J. W. Vaughan, H. Wallach, H. Daumé III, and K. Crawford, “Datasheets for datasets,” Commun. ACM, vol. 64, no. 12, pp. 86–92, 2021.
- [16] F. Schroff, D. Kalenichenko, and J. Philbin, “FaceNet: A unified embedding for face recognition and clustering,” in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), 2015, pp. 815–823.
- [17] J. Deng, J. Guo, N. Xue, and S. Zafeiriou, “ArcFace: Additive angular margin loss for deep face recognition,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2019, pp. 4690–4699.
- [18] M. Kim, A. K. Jain, and X. Liu, “AdaFace: Quality adaptive margin for face recognition,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2022, pp. 18 750–18 759.
- [19] G. Zoss, P. Chandran, E. Sifakis, M. Gross, P. Gotardo, and D. Bradley, “Production-ready face re-aging for visual effects,” ACM Trans. Graph. (SIGGRAPH Asia), vol. 41, no. 6, pp. 1–12, 2022.
- [20] European Parliament and Council of the European Union, “Regulation (eu) 2016/679 (general data protection regulation),” Official Journal of the European Union, L119, 2016.