

# Возраст-инвариантное сопоставление личности по «естественно заякоренным» постам соцсетей: naturally-supervised longitudinal-сигнал

Данил Ф. Вольхин и Иван С. Копылов

Аннотация—Кросс-возрастная верификация лиц — определение того, изображён ли на двух фотографиях, снятых с разрывом в годы, один и тот же человек — трудна: возраст сильно меняет внешность, а модели склонны опираться на возраст как на шорткат. Мы изучаем data-centric вопрос: можно ли получить супервизию для возрастной инвариантности без вручную размеченного longitudinal-датасета? Мы показываем, что мультифото-посты «тогда/сейчас», где один человек показан в разном возрасте, дают «естественно заякоренные» позитивные пары личности, и что дообучение слабого распознавателя на них учит переносимой возрастной инвариантности. Наша супервизия не требует ручных меток (нет человеческой разметки личности или возраста), хотя конвейер использует LLM-парсер подписей и кластеризацию эмбеддингов; поэтому мы называем её naturally supervised и аудлируем эти компоненты. На внешнем кросс-возрастном бенчмарке FG-NET дообучение намеренно слабого обучаемого backbone поднимает large-gap ( $\geq 25$  лет) ROC-AUC с 0.736 до 0.848 ( $+0.112 \pm 0.001$  по трём сидам) ценой лишь  $-0.019$  на LFW; AgeDB-30 и CALFW подтверждают. Эффект (а) превосходит синтетическое старение даже с настоящей генеративной aging-моделью; (б) воспроизводится на трёх loss-семействах, двух архитектурах, двух независимых источниках одной платформы и двух обучающих целях — наш простой pair-contrastive objective совпадает с канонической ArcFace-классификацией на ключевой внешней метрике (0.848 против 0.851). Таким образом, результат — это целевая large-gap-устойчивость, а не равномерный прирост верификации; мы делаем ограниченное утверждение: в рамках этого протокола и среди рассмотренных целей вклад naturally-supervised данных в large-gap-прирост больше, чем выбор между loss-семействами. Прирост механистически связан со снятием возрастного шортката: точность frozen-моделей падает почти к случайности при age-matched негативах, а наши пары её восстанавливают. Метод данные-эффективен ( $\approx 96\%$  прироста на 10% личностей). В аудите по кажущимся полу/возрасту ни одна страта не ухудшается, а наибольший значимый прирост — у младшей группы (0–17), где базовая модель слабее всего. Дополнительно мы даём калиброванную  $P(\text{same} \mid \text{cosine}, \text{age-gap})$  и конвейер чистки, главная находка которого — около половины сырых «позитивов» были near-duplicate кадрами, завышавшими внутренние метрики.

Index Terms—Кросс-возрастное распознавание лиц, возраст-инвариантное представление, naturally/weakly-

supervised личность, курирование датасета, shortcut learning, справедливость, калибровка.

## I. Введение

КРОСС-ВОЗРАСТНАЯ верификация важна для архивного поиска, восстановления доступа и авторизованного поиска пропавших людей. Сложность не в том, чтобы различить случайных людей, а в том, чтобы отличить одного и того же человека сквозь возраст от разных людей схожего возраста и внешности. Разметка longitudinal-пар личности (один человек на протяжении многих лет) дорога и редка, что является узким местом supervised-подходов; свежие работы продолжают отмечать слабую кросс-датасетную генерализацию и дефицит качественных longitudinal-данных.

Гипотеза. Мультифото-пост «тогда/сейчас» с одним человеком в разном возрасте даёт  $\binom{n}{2}$  позитивных пар личности без ручной разметки; подпись с возрастами добавляет age-anchor. Это масштабируемый naturally-supervised сигнал кросс-возрастной идентичности, и дообучение слабого распознавателя на нём должно переноситься на внешние бенчмарки.

Вклад (ограниченные claims). (1) Naturally-supervised (без ручных меток) longitudinal-сигнал, намайненный из соцпостов. (2) Строгий протокол атрибуции (один слабый обучаемый backbone, frozen против дообученного, внешняя оценка), изолирующий вклад данных от ёмкости сети. (3) Взаимоусиливающие контроли (loss-семейство, архитектура, источник, обучающая цель, real-vs-synthetic, диагностика шортката), обосновывающие ограниченный тезис: в этом протоколе и среди рассмотренных целей вклад данных в large-gap-прирост больше, чем выбор между loss-семействами. (4) Конвейер курирования с аудитом автоматических компонентов и находка, что сырой счёт позитивов раздут примерно вдвое near-duplicate кадрами. (5) Прикладная калибровка и аудит по кажущимся стратам с доверительными интервалами.

Мы подчёркиваем, что новизна data-centric, а не архитектурная — новый источник супервизии — и оценивать её следует по этой оси.

## II. Связанные работы и позиционирование

Три семейства-предшественника. Дискриминативная возраст-инвариантная FR на размеченных данных:

Рукопись подготовлена в 2026 г.

Д. Ф. Вольхин (автор) и И. С. Копылов (научный руководитель) — Национальный исследовательский университет «Высшая школа экономики» (НИУ ВШЭ), Москва, Россия (e-mail: deneal123@mail.ru; ORCID: 0009-0000-8108-8814).

Код, конфигурации и обезличенный протокол бенчмарка доступны по адресу <https://github.com/deneal123/ChildVSAdult>.

OE-CNN (ортогональное разложение признаков) [1], DAL (decorrelated adversarial learning) [2] и MTLFace (multi-task: распознавание, синтез возраста и attention-decomposition) [3] достигают высокой точности, но обучаются на данных с ручными метками личности И возраста (CACD [4], MORPH [5], AgeDB [6], FG-NET [7]). Cross-age contrastive с синтетикой: CACCon [8] добавляет синтезированный cross-age семпл и triplet-loss; OrdCon [9] использует order-enhanced contrastive. Синтетическое старение: систематические оценки показывают лишь частичную пользу [10]. Общий self-supervised FR (SimCLR-аугментации [11]) не имеет identity-якорей во времени. Мы майним структуру «один пост = один человек в разном возрасте» как бесплатный генератор позитивов. Таблица I позиционирует нас относительно этих методов.

Мы отчитываемся на канонических кросс-возрастных бенчмарках этих методов (AgeDB-30, CALFW [12], FG-NET; CALFW специально создан как более жёсткий age-gapped LFW [13]). Цель — не побить абсолютный SOTA (мы используем слабый backbone для чистой атрибуции), а измерить величину и переносимость выигрыша от naturally-supervised источника; разд. V-F обучает каноническую SOTA-цель на наших данных напрямую.

### III. Данные: «естественно заякоренные» longitudinal-пары

Источник. Две публичные «тогда/сейчас» мультифото-стены VK (одна платформа, русскоязычный контекст). Лица детектируются и выравниваются по 5-точечному ArcFace-шаблону (InsightFace RetinaFace [14], buffalo\_l). Usable-лицо проходит пороги det-score, минимального размера, размытия и единственного целевого лица (разд. IX). Сырой намайненный корпус сведён в Таблице II (слева).

#### A. Извлечение возраста

Подписи парятся регулярными выражениями (русские паттерны плюс слэш-формат «6/18/21», один возраст на фото) и LLM (GigaChat). LLM-аудит всех 33 697 мультифото-подписей (Таблица III) показал, что LLM существенно точнее regex — не принимает календарные годы или разрывы за возраст и восстанавливает второй возраст — расходясь на 27.2% постов, в основном в пользу LLM.

#### B. Личности и leakage-safe сплит

Наивное «один пост = одна личность» недосчитывает: человек повторяется в постах. Мы кластеризуем пост-группы в личности по близости эмбедингов ( $\cos \geq 0.85$ ), получая 21 848 личностей из 27 487 пост-групп ( $\approx 20\%$  повторов), и делим по человеку (не по посту). Ручная проверка high-cosine пар показала, что косинус не разделяет look-alike от same-person в зоне 0.55–0.8, поэтому порог слияния намеренно консервативен (0.85).

#### C. Аудит автоматической супервизии

Поскольку сигнал naturally (не человечески) supervised, автоматические компоненты — потенциальный скрытый шум меток и аудируются: согласие LLM-vs-regex по возрасту (Таблица III); ручная проверка идентичности high-cosine пар; и gender-consistency внутри личности как бесплатный детектор шума (2 919 мультифото-групп с согласием  $< 0.6$  помечают вероятный мульти-человек). Отдельный human-audited subset (точность извлечения возраста, точность group-integrity, error-matrix, согласие человек–LLM,  $\kappa$ ) сопровождает релиз.

#### D. Конвейер курирования и его главная находка

Три шага: (i) метаданные кажущихся пола/возраста (оценщик) на лицо, агрегированные по личности — корпус на 76.7% apparent-female / 23.3% apparent-male; (ii) LLM-валидация целостности групп (Таблица IV) — кластеризация по личности уже развела большинство мульти-человек постов, поэтому шумными помечены лишь 421 person-группа; (iii) near-duplicate дедуп внутри каждой личности ( $\cos \geq 0.97$ ), убирающий 8 190 лиц ( $\approx 17\%$ ).

Ключевая находка. Поскольку позитивы квадратичны по числу лиц в группе, удаление near-duplicate обрушило позитивы  $65\,897 \rightarrow 31\,865$  (–52%): около половины сырых «позитивов» были дубликатами кадров (одна съёмка, серия или репост), завышавшими внутренние метрики. После курирования frozen-базлайн на внутреннем тесте честно падает (our.overall  $0.856 \rightarrow 0.836$ ; our.25 + 0.705  $\rightarrow 0.640$ ), вскрывая более трудный и честный бенчмарк. Внешние бенчмарки не затронуты. Это переносимый урок для майнинга longitudinal-пар из соцсетей.

#### E. Карточка датасета (кратко)

Provenance, права и governance хранятся по элементу (источник, URL, дата сбора, статус лицензии/consent, разрешённое использование, политика хранения, статус удаления, статус ревью). Сбор: публичные стены VK. Назначение: исследование consent-based кросс-возрастного сопоставления. Вне scope: массовая идентификация, слежка, деанонимизация. Несовершеннолетние: режим child $\leftrightarrow$ adult в scope только при явных правовых/этических рамках; статус ревью отслеживается по элементу, удаление по запросу поддержано. Полная карточка [15] сопровождает релиз.

### IV. Метод, протокол и статистика

Протокол атрибуции. Сравнивать adapter поверх замороженного сильного ArcFace с frozen-ArcFace некорректно (adapter лишь деформирует почти идеальные эмбединги). Вместо этого мы используем один слабый обучаемый backbone (FaceNet InceptionResnetV1 [16], CASIA-WebFace) и сравниваем (а) frozen  $\rightarrow$  метрика бенчмарка против (б) мягкого дообучения головы на

Таблица I  
Позиционирование относительно предшественников.

| Работа                       | Супервизия              | Механизм                            | Наше отличие                                 |
|------------------------------|-------------------------|-------------------------------------|----------------------------------------------|
| OE-CNN (2018) [1]            | размеч. id+age          | ортогональное разложение            | label-free источник, не decomposition        |
| DAL (2019) [2]               | размеч. id+age          | adversarial id/age факторизация     | mined-пары + проще objective                 |
| MTLFace (2021) [3]           | размеч. id+age          | распознавание + синтез (multi-task) | проще конвейер; новый источник супервизии    |
| CACon (2023) [8]             | semi-sup. + синтетика   | contrastive на синтезе              | реальные mined-пары > синтетика (разд. V-B)  |
| Synthetic Ageing (2024) [10] | синтетика               | обучение на состаренных             | у нас реальный mining как тезис              |
| OrdCon (2025) [9]            | age-ordered contrastive | order-enhanced признаки             | майним естественные пары, без явного порядка |

Таблица II  
Масштаб датасета (сырой mining) и после курирования (разд. III-D).

| Стадия                 | Посты  | Фото   | Usable-лица | Личности (группы) | Позитивные пары |
|------------------------|--------|--------|-------------|-------------------|-----------------|
| Сырой mining (2 стены) | 44 609 | 84 147 | 49 606      | 21 848            | 65 897          |
| После курирования      | —      | —      | 40 586      | 21 427            | 31 865          |

Таблица III  
Аудит извлечения возраста: LLM против regex (33 697 постов с подписью).

| Категория                               | n      | Доля  |
|-----------------------------------------|--------|-------|
| Согласие (те же возрасты или оба пусты) | 24 531 | 72.8% |
| LLM нашёл (regex пропустил)             | 3 656  | 10.8% |
| Расхождение возрастов                   | 4 658  | 13.8% |
| LLM пусто (regex нашёл)                 | 852    | 2.5%  |

Таблица IV  
LLM-классификация целостности групп (33 697 постов).

| Категория                               | n      | Доля  |
|-----------------------------------------|--------|-------|
| Single (один человек в разном возрасте) | 31 275 | 92.8% |
| Multi-person (разные люди)              | 2 034  | 6.0%  |
| Unknown                                 | 336    | 1.0%  |
| Meme / collage                          | 52     | 0.2%  |

наших парах → метрика бенчмарка. Обучение использует margin contrastive loss на выровненных кропах. Оценка — на внешних бенчмарках (LFW, AgeDB-30, CALFW, FG-NET) для чистой атрибуции переноса; внутренний тест (our.\*) — вторичная диагностика. Сила backbone варьируется (разд. V-C). Дизайн жертвует абсолютным качеством ради причинной атрибуции.

Backbone. FaceNet (слабый); ArcFace iResNet-50 [17] (CASIA-FaceV5; слабый, другая архитектура); AdaFace IR-50/IR-101 [18] (WebFace; сильный; чистый депт-контроль); ArcFace iResNet-100 (сильный).

Бенчмарки и метрики. LFW (10-fold accuracy), AgeDB-30 и CALFW (выровненные пары; ROC-AUC и 10-fold accuracy), FG-NET (ROC-AUC overall и на large-gap  $\geq 25$  лет). Мы намеренно не опираем headline только на FG-NET (мал, стар, частичное покрытие

детектором): AgeDB-30 и CALFW подтверждают. Различаем threshold-free метрики (ROC-AUC) и threshold-based (accuracy, TAR@FAR).

Статистика. Наш первичный эндпойнт — FG-NET large-gap ( $\geq 25$  лет) ROC-AUC, с нулевой гипотезой, что дообучение на намайненных парах не улучшает его относительно frozen-базлайна (прирост  $\leq 0$ ); AgeDB-30, CALFW и внутренний кросс-возрастной тест — вторичные эндпойнты, а easy-LFW ассурасу отслеживается как контроль забывания. Headline-прирост — среднее  $\pm$  std по трём сидам (сид-разброс отражает стохастичность обучения, не полную неопределённость оценки). Аудит справедливости использует парный перцентильный bootstrap (1000 ресэмплов, ресэмплинг пар с пересчётом обеих моделей на одной выборке) для прироста, учитывая корреляцию frozen/tuned. Таблица VI приводит bootstrap-CI, EER и TAR@FAR для ключевых сравнений (внутренний тест дополнительно использует identity-level bootstrap с ресэмплингом личностей), а поправка Holm применяется по стратифицированным тестам справедливости.

Очищенный датасет. Все headline-эксперименты — на очищенных данных разд. III-D: 21 427 групп личностей, 40 586 лиц, 31 865 позитивов; сплит train 22 179 / val 4 579 / test 5 107 со сбалансированными негативами по сплитам.

## V. Результаты

### A. Главный эффект и self-supervised ablation

Слабый FaceNet, мягко дообученный на наших парах, поднимает FG-NET large-gap ROC-AUC  $0.736 \rightarrow 0.848$  ( $+0.112 \pm 0.001$ ), тогда как easy-LFW падает лишь на  $-0.019$ , а AgeDB-30/CALFW почти не двигаются (Таблица V). Ablation изолирует источник: same-post пары не используют ручных меток — ни личности,

ни возраста — и дают почти весь прирост; явные age-anchor добавляют лишь +0.009 на 25+ (pre-clean ablation). Поэтому метод по сути self-supervised по личности, а возрастная супервизия — тонкая надстройка.

Прирост статистически устойчив ( $\text{std} \leq 0.003$ ) и переживает чистку; внутренний кросс-возрастной прирост даже растёт на более трудном очищенном тесте (our.25+ +0.195), т.к. чистка опускает frozen до 0.640, а +pairs восстанавливает до 0.835.

Bootstrap-доверительные интервалы (сид 42) подтверждают первичный эндпоинт: FG-NET large-gap растёт с 0.736 [0.70, 0.78] до 0.848 [0.82, 0.88] с непересекающимися 95% CI; equal-error rate почти вдвое меньше (0.335→0.219), а TAR@FAR=1% почти вдвое больше (0.21→0.39). На внутреннем 25+ тесте прирост сохраняется при более консервативном identity-level bootstrap (ресэмплинг личностей, не пар): +pairs 0.838 [0.80, 0.88] против frozen 0.640 [0.59, 0.69] — интервал шире pair-level, что ожидаемо, когда пары делят личности. Операционные точки и интервалы по всем бенчмаркам — в Таблице VI.

#### В. Реальные пары превосходят синтетическое старение

Замена реальных позитивов синтетически состаренными — доменный прокси и настоящая re-aging-сеть (FRAN [19]) — не просто не помогает, а активно вредит на очищенных данных: FRAN даёт FG-NET large-gap 0.727 (ниже frozen 0.736), а our.25+ рушится до 0.549 (ниже frozen 0.640), тогда как реальные пары дают +0.112 / +0.198 (Таблица VII). Identity-preserving старение учит текстурным артефактам, а не реальной longitudinal-вариации (поза, камера, эпоха). (Кропы 112px ограничивают fidelity FRAN, рассчитанного на ≈1024px.)

#### С. Кривая headroom и режим сильных backbone

Прирост воспроизводится на FaceNet, ArcFace iResNet и AdaFace IR-50/IR-101 (три loss-семейства, две архитектуры) и монотонно убывает с силой frozen (Таблица VIII, Рис. 1); чистый депт-контроль (AdaFace IR-50 → IR-101) это подтверждает. Прямо заявляем: сильные насыщенные backbone не растут и слегка забывают при дообучении; мягкий learning rate (1e-5) примерно вдвое уменьшает забывание, но не превращает его в прирост. Вклад специфичен для слабых/средних backbone с кросс-возрастным запасом — ограничение, которое мы не скрываем (разд. VII).

#### Д. Закон масштабирования данных

Варьируя долю обучающих личностей (val/test фиксированы), прирост насыщается очень рано: ≈96% полного прироста FG-NET large-gap достигается уже на 10% личностей (≈1500), с плато от 25% (Таблица IX, Рис. 2); небольшой провал на полном объёме (0.50→1.00) — в пределах сид-разброса: кривая плоская, не монотонная, после ≈10%. Сигнал данные-эффективен; дальнейший рост требует более трудных




Рис. 1. Кривая headroom: прирост от +pairs на FG-NET large-gap монотонно убывает с усилением frozen-backbone, пересекая ноль для сильных насыщенных моделей.




Рис. 2. Закон масштабирования: внешний (FG-NET large-gap) и внутренний (our.25+) ROC-AUC против числа обучающих личностей (лог-шкала). Около 96% прироста достигается на 10% личностей; пунктир — frozen-базлайны.

данных (большие разрывы, hard-позитивы), а не просто большего объёма.

#### Е. Механизм — возрастной шорткат

При age-matched негативах (тот же возрастной бакет, разные люди) точность frozen на внутреннем 25+ тесте падает с 0.640 до 0.517 (почти к случайности, 0.5), а реальные пары восстанавливают её до 0.838 (Рис. 3) — прямое доказательство, что frozen-модели различают кросс-возрастные пары во многом по возрасту, а наши пары учат различать по личности. Линейный probe уточняет это представлено (Таблица X): кажущийся возраст остаётся хорошо декодируемым из identity-эмбединга у всех моделей (≈0.63–0.65 bal-acc ≫ 0.25 случайность) и меняется лишь слегка, тогда как identity-AUC растёт — то есть метод учит инвариант-

Таблица V

Главный результат: слабый FaceNet frozen против +pairs, три сйда, очищенные данные. Прирост до чистки — для сравнения.

| Метрика              | Frozen | +pairs (сред. $\pm$ std) | Прирост | (до чистки) |
|----------------------|--------|--------------------------|---------|-------------|
| FG-NET large-gap     | 0.7361 | 0.8484 $\pm$ 0.0007      | +0.1124 | +0.1215     |
| FG-NET ROC           | 0.8955 | 0.9230 $\pm$ 0.0006      | +0.0275 | +0.0277     |
| our.25+ (внутр.)     | 0.6403 | 0.8348 $\pm$ 0.0027      | +0.1946 | +0.1677     |
| our.overall (внутр.) | 0.8363 | 0.9163 $\pm$ 0.0009      | +0.0801 | +0.0764     |
| LFW accuracy         | 0.9688 | 0.9503 $\pm$ 0.0031      | −0.0185 | −0.0283     |
| AgeDB-30 ROC         | 0.9530 | 0.9462 $\pm$ 0.0013      | −0.0068 | −0.0155     |
| CALFW ROC            | 0.9482 | 0.9489 $\pm$ 0.0014      | +0.0007 | −0.0030     |

Таблица VI

Операционные точки и 95% bootstrap-CI (FaceNet frozen vs. +pairs, сид 42). Все значения — ROC-AUC; LFW показан как ROC-AUC для согласованности (его 10-fold accuracy — в Таблице V). Внешние CI — pair-level; внутренний тест дополнительно использует identity-level bootstrap (см. текст).

| Бенчмарк         | Frozen AUC [95% CI] | +pairs AUC [95% CI] | EER (fr. $\rightarrow$ +p.) | TAR@1%                    | TAR@0.1%                  |
|------------------|---------------------|---------------------|-----------------------------|---------------------------|---------------------------|
| FG-NET large-gap | 0.736 [0.70, 0.78]  | 0.848 [0.82, 0.88]  | 0.335 $\rightarrow$ 0.219   | 0.209 $\rightarrow$ 0.386 | 0.074 $\rightarrow$ 0.154 |
| FG-NET overall   | 0.896 [0.89, 0.90]  | 0.922 [0.92, 0.93]  | 0.186 $\rightarrow$ 0.151   | 0.502 $\rightarrow$ 0.562 | 0.315 $\rightarrow$ 0.308 |
| AgeDB-30         | 0.953 [0.95, 0.96]  | 0.945 [0.94, 0.95]  | 0.115 $\rightarrow$ 0.126   | 0.525 $\rightarrow$ 0.510 | 0.285 $\rightarrow$ 0.309 |
| CALFW            | 0.948 [0.94, 0.95]  | 0.948 [0.94, 0.95]  | 0.116 $\rightarrow$ 0.117   | 0.580 $\rightarrow$ 0.624 | 0.213 $\rightarrow$ 0.320 |
| LFW (AUC)        | 0.994 [0.99, 1.00]  | 0.987 [0.98, 0.99]  | 0.032 $\rightarrow$ 0.052   | 0.940 $\rightarrow$ 0.869 | 0.858 $\rightarrow$ 0.575 |

Таблица VII

Реальные против синтетических позитивов (FaceNet, очищенные данные).

| Метрика          | Frozen | +реал. | +синт. (прокси) | +синт. (FRAN) |
|------------------|--------|--------|-----------------|---------------|
| FG-NET large-gap | 0.736  | 0.848  | 0.761           | 0.727         |
| our.25+          | 0.640  | 0.838  | 0.594           | 0.549         |

Таблица VIII

Headroom: FG-NET large-gap по силе backbone (очищенные данные,  $1r\ 3e-5$ ).

| Backbone (сила)                | Frozen | +pairs | $\Delta$ large-gap | $\Delta$ our.25+ |
|--------------------------------|--------|--------|--------------------|------------------|
| FaceNet (слабый)               | 0.736  | 0.848  | +0.112             | +0.198           |
| ArcFace r50 (слабый, др. арх.) | 0.764  | 0.805  | +0.041             | +0.133           |
| AdaFace IR-50 (сильный)        | 0.917  | 0.924  | +0.007             | +0.004           |
| ArcFace r100 (сильный)         | 0.954  | 0.915  | −0.039             | −0.002           |
| AdaFace IR-101 (сильный)       | 0.957  | 0.931  | −0.026             | −0.006           |

Таблица IX

Закон масштабирования (FaceNet, очищенные; val/test фиксированы).

| Доля train | # личностей       | FG-NET large-gap | our.25+ |
|------------|-------------------|------------------|---------|
| frozen     | 0                 | 0.736            | 0.640   |
| 0.10       | $\approx 1\ 500$  | 0.845            | 0.814   |
| 0.25       | $\approx 3\ 750$  | 0.853            | 0.842   |
| 0.50       | $\approx 7\ 499$  | 0.864            | 0.848   |
| 1.00       | $\approx 14\ 998$ | 0.848            | 0.838   |

Таблица X

Линейный probe age-leakage (очищенные данные; случайность = 0.25).

| Модель             | Age-probe bal. acc. $\downarrow$ | Identity ROC-AUC $\uparrow$ |
|--------------------|----------------------------------|-----------------------------|
| frozen             | 0.651 $\pm$ 0.019                | 0.836                       |
| +pairs             | 0.629 $\pm$ 0.012                | 0.916                       |
| +pairs+disentangle | 0.632 $\pm$ 0.017                | 0.918                       |

F. Сравнение objective: обучение SOTA-цели на наших данных

Мы обучаем каноническую цель современной FR — ArcFace-margin классификацию личности [17] (ядро OE-CNN/MTLFace) — на наших naturally-supervised личностях (9204 класса), тот же слабый backbone, score и протокол. На ключевой внешней метрике кон-

ную метрику (косинус перестаёт опираться на возрастную ось), а не age-free представление; явный adversarial disentanglement не снижает leakage дополнительно.




Рис. 3. Возрастной шорткат. На identity-only тесте (age-matched негативы) frozen падает почти к случайности; дообучение на наших парах восстанавливает различие по личности.




Рис. 4. Сравнение objective: pair-contrastive и каноническая ArcFace-классификация совпадают на кросс-возрастном переносе; ArcFace чуть меньше забывает на easy-бенчмарках.

трастив и ArcFace совпадают (Таблица XI, Рис. 4). Делаем ограниченный вывод: в этом протоколе и среди рассмотренных целей вклад источника данных доминирует над выбором objective — а не «метод не важен вообще». ArcFace дополнительно забывает меньше на easy-бенчмарках — практическая рекомендация.

#### G. Аудит по кажущимся стратам

Стратифицируя по кажущимся полу/возрасту якоря пары (оценка, не самоидентификация), ни одна страта не ухудшается, и каждый прирост значим (95% парный bootstrap-CI > 0; Таблица XII, Рис. 5). Максимальный прирост — у младшей группы 0–17 (frozen 0.750 → +pairs 0.880, +0.130, CI не пересекается со взрослыми полосами) — метод усиливает там, где базовая модель слабее всего (режим child↔adult), сужая кажущийся демографический разрыв. Мы намеренно избегаем сло-




Рис. 5. Аудит по кажущимся стратам: frozen против +pairs ROC-AUC по стратам кажущихся пола/возраста. Все страты улучшаются; максимальный прирост — у младшей группы (0–17), где frozen слабее всего. Усы — 95% парный bootstrap-CI прироста,  $n$  — число позитивных пар на страту (у разреженной страты 45+,  $n=153$ , интервал соответственно широк).

ва «справедлив» как решённого свойства: источник перекошен в женскую сторону (76.7%), атрибуты кажущиеся (не этничность и не юридические категории), а 45+ разрежена.

#### H. Перенос между источниками

Обучение на одном сообществе и тест на held-out другим переносит прирост: внешний FG-NET large-gap +0.113 (против +0.112 within-source — практически идентично) и внутренний +0.092 на held-out сообществе. Мы формулируем это как перенос между двумя независимыми источниками внутри одного платформенного домена, а не platform-agnostic или web-scale генерализацию.

#### I. Калибровка

Сырой косинус (Platt) плохо калиброван по бинам разрыва — переуверен на 15–25 лет (ECE 0.052); калибратор  $P(\text{same} \mid \text{cosine}, \text{age-gap})$  чинит каждый бин (15–25 → 0.017) и улучшает общий Brier (0.035 → 0.029) — пригодная age-aware вероятность того же человека.

#### J. Disentanglement

Явное удаление возраста (gradient reversal + age-голова, в стиле MTLFace) даёт малый, но устойчивый кросс-возрастной прирост (+0.0055 FG-NET large-gap, +0.0145 our.25+ над +pairs) без вреда easy-бенчмаркам (даже чуть выше +pairs: LFW 0.951 против 0.946); в абсолютном его large-gap ( $\approx 0.853$ ) на уровне ArcFace-цели из разд. V-F (0.851), что согласуется с тем, что

Таблица XI  
Сравнение objective (FaceNet, очищенные данные).

| Метрика          | Frozen | +pairs (контрастив) | +ArcFace (класс.) |
|------------------|--------|---------------------|-------------------|
| FG-NET large-gap | 0.736  | 0.848               | 0.851             |
| our.25+          | 0.640  | 0.838               | 0.868             |
| LFW accuracy     | 0.969  | 0.946               | 0.952             |
| AgeDB-30 ROC     | 0.953  | 0.945               | 0.947             |

Таблица XII  
Кажущиеся страты пол/возраст (FaceNet, очищенные; 95% парный bootstrap-CI прироста).

| Страта        | $n_{pos}$ | Frozen | +pairs | Прирост | 95% CI           |
|---------------|-----------|--------|--------|---------|------------------|
| overall       | 5 107     | 0.836  | 0.916  | +0.080  | [+0.075, +0.086] |
| apparent F    | 3 790     | 0.840  | 0.923  | +0.084  | [+0.077, +0.090] |
| apparent M    | 1 317     | 0.838  | 0.897  | +0.059  | [+0.048, +0.071] |
| возраст 0–17  | 1 123     | 0.750  | 0.880  | +0.130  | [+0.113, +0.146] |
| возраст 18–29 | 3 159     | 0.872  | 0.936  | +0.064  | [+0.058, +0.069] |
| возраст 30–44 | 672       | 0.822  | 0.893  | +0.070  | [+0.054, +0.087] |
| возраст 45+   | 153       | 0.859  | 0.893  | +0.034  | [+0.004, +0.064] |

Таблица XIII  
Майнинг hard-негативов (FaceNet, очищенные данные; внешние бенчмарки, один прогон).

| Метрика          | Frozen | +pairs | +pairs+hard-ner |
|------------------|--------|--------|-----------------|
| FG-NET large-gap | 0.736  | 0.848  | 0.866           |
| FG-NET ROC       | 0.896  | 0.923  | 0.927           |
| LFW accuracy     | 0.969  | 0.950  | 0.934           |
| AgeDB-30 ROC     | 0.953  | 0.946  | 0.931           |
| CALFW ROC        | 0.948  | 0.949  | 0.934           |

потолок cross-age задают данные — а не objective или disentangle-надстройка. Вместе с разд. V-E это показывает, что явная age-супервизия — тонкая надстройка над данными.

## K. Майнинг hard-негативов

Добавление самых трудных кросс-личностных негативов в дообучение — top-5 наиболее похожих по косинусу лиц других людей на якорь (косинус в «трудной» полосе, исключая near-duplicate/uncertain диапазон) — дополнительно обостряет кросс-возрастное различие: FG-NET large-gap растёт до 0.866 (с 0.848 при случайных негативах), но easy-бенчмарки забываются сильнее (LFW 0.969→0.934 против 0.950 у +pairs; AgeDB-30 и CALFW аналогично; Таблица XIII). То есть hard-негативы меняют калибровку лёгких пар на кросс-возрастное разделение — полезно для cross-age retrieval, не для общего верификатора. (Один прогон; внутренний hard-neg тест у frozen почти случаен по построению и несопоставим со стандартным внутренним тестом.)

## VI. Обсуждение

Вклад — масштабируемый naturally-supervised источник longitudinal-супервизии и доказательство того,

что он учит переносимой возрастной инвариантности, которую не заменяет синтетика и не объясняет явная age-супервизия. Взаимоусиливающие контроли — loss-семейство, архитектура, источник, обучающая цель — сходятся к ограниченному выводу: в этом протоколе данные доминируют над objective среди рассмотренных вариантов. Диагностика шортката даёт чистую identity-only метрику и объясняет механизм; находка чистки (половина сырых позитивов — дубликаты) сама по себе является методологическим уроком. Это data-centric вклад, не архитектурный; ряд claims ограничен нашей двухисточниковой, одноплатформенной, кажущейся-атрибутной постановкой.

## VII. Ограничения

- Зависимость от backbone: прирост сосредоточен у слабых/средних backbone; сильные насыщенные не растут и слегка забывают (мягкий lr смягчает, но не обращает).
- Внешняя валидность: два сообщества VK, одна платформа, один язык/культурный контекст; перекос в женскую сторону (76.7%); разреженность на apparent 45+. Перенос показан между этими источниками и на стандартные бенчмарки, а не platform-agnostic генерализация.
- Только кажущиеся атрибуты в аудите справедливости (оценка, не самоидентификация пола/этничности).
- Naturally-supervised, не строго label-free: LLM парсит возраст и валидирует целостность групп; кластеризация формирует личности — аудировается (разд. III-C), но остаётся источником скрытого шума.
- Статистика: сид-разброс, парный bootstrap (справедливость) и CI / EER / TAR@FAR по бенчмаркам (Таблица VI, включая identity-level bootstrap) при-

ведены в тексте; DeLong-тесты и полная поправка на множественные сравнения по каждой ячейке — в release-supplement.

- Масштаб и возраст бенчмарков: мы оцениваем на стандартном для области наборе кросс-возрастных бенчмарков — AgeDB-30 и CALFW (по 6 000 пар) и FG-NET для явного подмножества  $\geq 25$  лет — тех же, что используют OE-CNN/DAL/MTLFace, что обеспечивает сопоставимость, но наследует их ограниченный масштаб и возраст (FG-NET особенно мал, с частичным покрытием детектором, поэтому headline не опирается только на него). Наш очищенный внутренний тест (5 107 кросс-возрастных позитивов с контролируемыми негативами) — крупный современный дополнительный; большой независимый не-VK longitudinal-набор и специализированный child $\leftrightarrow$ adult бенчмарк остаются приоритетом дальнейшей работы.
- Полные SOTA-конвейеры не воспроизведены целиком: по замыслу мы обучаем общее ядро современной AIFR — ArcFace-цель с угловым margin — в нашем протоколе со слабым backbone ради чистой атрибуции, а не сравнения в лидерборде. Разд. V-F показывает, что эта цель совпадает с нашим контрастивом на ключевой внешней метрике, т.е. выигрыш определяется не objective; опущенные метод-специфичные надстройки (генеративная ветвь синтеза возраста MTLFace, ортогональное разложение подпространств OE-CNN) уточняют это общее ядро и ортогональны нашему утверждению об источнике супервизии. Закрывает ли полный SOTA-конвейер на naturally-supervised данных остаточный абсолютный разрыв — чётко очерченное продолжение.

### VIII. Этика, правовая основа и data governance

Это чувствительное биометрическое исследование; мы рассматриваем governance как полноценный компонент, а не дисклеймер. Разрешённое использование ограничено controlled / consent-based / human-reviewed приложениями (архивы и семейные фото с очищенными правами, авторизованный гуманитарный поиск, восстановление доступа); система выдаёт кандидатов для проверки человеком, а не автоматическое решение. Запрещено: массовая идентификация, деанонимизация, слежка и любая обработка данных несовершеннолетних без правовой основы.

#### A. Этическое одобрение и правовая основа

Этическое одобрение. Исследование рассмотрено [название этического комитета] Национального исследовательского университета «Высшая школа экономики»; оно было [одобрено по протоколу № XXXX / признано освобождённым] [дата]. Согласие. Поскольку данные взяты из публичных постов без реальной возможности связаться с субъектами, индивидуальное информированное согласие на участие и на публикацию не получалось; мы опираемся на научно-исследовательскую основу и меры обезличивания разд. VIII-B.

Замечание (удалить перед подачей). IEEE T-BIOM отклоняет без рецензирования исследования на людях без заявления об этическом одобрении (или документированном освобождении). Получите одобрение этического комитета НИУ ВШЭ или письменное освобождение, затем заполните красным название комитета, протокол/освобождение и дату выше. Формулировку «без индивидуального согласия» следует согласовать с этим комитетом.

Данные собраны с публичных «тогда/сейчас» стен сообществ через официальный API платформы. Подчёркиваем: официальный доступ к API и добровольная публикация сами по себе НЕ дают права на биометрическую обработку. По 152-ФЗ поправка 2020 г. (519-ФЗ) заменила «общедоступные» данные на «данные, разрешённые субъектом для распространения» (требуется отдельное согласие), а ст. 11 требует письменного согласия на биометрию, используемую для установления личности; по GDPR [20] лицо, обработанное для уникальной идентификации, — спецкатегория (ст. 9), где исключение «manifestly made public» трактуется узко (ср. санкции против Clearview AI). Явного/письменного согласия у нас нет. Мы опираемся на научно-исследовательскую основу (GDPR ст. 6(1)(f) и 9(2)(j) с safeguards ст. 89; аналогичная research-обработка по 152-ФЗ) и компенсируем мерами минимизации, не-распространения и обезличивания ниже. Мы прозрачно фиксируем этот пробел, а не заявляем полное соответствие, и рекомендуем этическую экспертизу организации и консультацию юриста по защите данных до любого развёртывания.

#### B. Обезличивание и политика релиза

Мы не публикуем сырые изображения лиц и сырые посты. Публичный релиз содержит только код, веса обученной модели, производные эмбединги, псевдонимизированный бенчмарк-протокол и агрегатную статистику. Все идентификаторы платформы (owner/photo/post ID) заменяются солёными хешами; подписи/комментарии (которые могут содержать имена) исключаются; хранятся только возраст-бакеты и псевдонимный person ID. Сырые кропы хранятся только локально под политикой хранения. Доступ к неагрегатным производным данным предоставляется квалифицированным исследователям по Data Use Agreement (только research; запрет реидентификации; запрет коммерческого/слежечного использования). Фигуры статьи не содержат идентифицируемых лиц (только агрегатные графики).

#### C. DPIA и минимизация

Поскольку обработка биометрическая и масштабная, проводится оценка воздействия на защиту данных (DPIA), сопровождающая релиз (ключевые риски: реидентификация, function creep, несовершеннолетние; меры — как в разд. VIII-B и разд. VIII-D). Минимизация данных применяется сквозно (храним кроп лица + возраст + псевдонимный ID, не имена и не соцграф).

## D. Несовершеннолетние

Режим  $\text{child} \leftrightarrow \text{adult}$  неизбежно включает изображения несовершеннолетних, чьи данные защищены строже всего (152-ФЗ; GDPR ст. 8). Элементы детского возраста (помеченные по кажущемуся возрасту) исключаются из любого релиза при отсутствии явных правовых рамок и проверяемого согласия законного представителя и используются только для агрегатного, не-распространяемого анализа.

## E. Права субъектов

Предоставлены публичный контакт и процедура takedown / удаления по запросу; удаление распространяется на производные артефакты через поле статуса удаления по элементу. Где права неясны, элемент удерживается. Полная карточка датасета [15] и DPIA сопровождают релиз.

## IX. Воспроизводимость

Мы публикуем скрипты и конфигурации. Ключевые детали: критерии usable-лица (det-score, минимальный размер, размытие по Лапласиану, единственное целевое лицо по IoU); детектор/выравнивание (InsightFace buffalo\_1 RetinaFace, 5-точечный ArcFace norm\_crop, 112 px; вход FaceNet 160 px); эмбединги (ArcFace w600k\_f50) для кластеризации/дедупа; кластеризация личности (union-find,  $\cos \geq 0.85$ ); дедуп (внутри личности union-find,  $\cos \geq 0.97$ ); LLM (GigaChat; полные версионированные системные промпты для извлечения возраста и валидации групп; concurrency 10; кэш, режюмируемо); сплит (по человеку, 70/15/15, сбалансированные негативы по сплитам, seed 42); сэмплинг негативов (кросс-личность случайно + age-matched вариант); обучение (margin contrastive, head scope, lr  $3e-5$  для слабых /  $1e-5$  для сильных; ArcFace-голова  $m=0.5$ ,  $s=32$ , lr  $1e-3$ ; ранняя остановка по внутреннему val-AUC; сиды 42/1/2); метрики (чистый NumPy ROC-AUC через Mann-Whitney, EER, TAR@FAR; 10-fold для выровненных пар).

Вычисления. Всё исследование выполняется на одном ноутбуке: одна NVIDIA RTX 3060 Laptop GPU (6 ГБ), AMD Ryzen 7 5800H (8 ядер / 16 потоков) и 16 ГБ RAM под Windows 11; программный стек — Python 3.12, PyTorch 2.12 (CUDA 13.2, cuDNN 9.2), InsightFace 1.0 / ONNX Runtime 1.26 для детекции и эмбедингов, scikit-learn 1.9 / Matplotlib 3.11 для анализа и фигур. Протокол со слабым backbone удерживает всё исследование в пределах 6 ГБ GPU.

## X. Заключение и дальнейшая работа

Мультифото-посты — дешёвый, масштабируемый naturally-supervised сигнал кросс-возрастной идентичности; дообучение слабого распознавателя на них даёт переносимый, кросс-источниковый, objective-устойчивый прирост, сосредоточенный на large-gap кросс-возрастном сопоставлении (с лишь незначительным забыванием на easy-бенчмарках), объяснимый

снятием возрастного шортката, данные-эффективный и не ухудшающий ни одну кажущуюся демографическую страту. Дальнейшая работа: независимый не-VK и  $\text{child} \leftrightarrow \text{adult}$ -специфичный внешний набор; human-audited subset супервизии (с agreement человек-LLM); per-point multi-seed доверительные полосы для кривых scaling и headroom; полные DeLong-тесты и поправочная поправка на множественные сравнения; полные SOTA-надстройки; реальная aging-модель на нативном разрешении; и калиброванный демонстратор в рамках governance-ограничений разд. VIII.

## Список литературы

- [1] Y. Wang, D. Gong, Z. Zhou, X. Ji, H. Wang, Z. Li, W. Liu, and T. Mei, "Orthogonal deep features decomposition for age-invariant face recognition," in Proc. Eur. Conf. Comput. Vis. (ECCV), 2018, pp. 738–753.
- [2] H. Wang, D. Gong, Z. Li, and W. Liu, "Decorrelated adversarial learning for age-invariant face recognition," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2019, pp. 3527–3536.
- [3] Z. Huang, J. Zhang, and H. Shan, "When age-invariant face recognition meets face age synthesis: A multi-task learning framework," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2021, pp. 7282–7291.
- [4] B.-C. Chen, C.-S. Chen, and W. H. Hsu, "Cross-age reference coding for age-invariant face recognition and retrieval," in Proc. Eur. Conf. Comput. Vis. (ECCV), 2014, pp. 768–783.
- [5] K. Ricanek and T. Tesafaye, "MORPH: A longitudinal image database of normal adult age-progression," in Proc. IEEE Int. Conf. Autom. Face Gesture Recognit. (FG), 2006, pp. 341–345.
- [6] S. Moschoglou, A. Papaioannou, C. Sagonas, J. Deng, I. Kotsia, and S. Zafeiriou, "AgeDB: The first manually collected, in-the-wild age database," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. Workshops (CVPRW), 2017, pp. 51–59.
- [7] G. Panis, A. Lanitis, N. Tsapatsoulis, and T. F. Cootes, "Overview of research on facial ageing using the FG-NET ageing database," IET Biometrics, vol. 5, no. 2, pp. 37–46, 2016.
- [8] H. Wang, V. Sanchez, and C.-T. Li, "Cross-age contrastive learning for age-invariant face recognition," in Proc. IEEE Int. Conf. Acoust. Speech Signal Process. (ICASSP), 2024, arXiv:2312.11195.
- [9] —, "From age estimation to age-invariant face recognition: Generalized age feature extraction using order-enhanced contrastive learning," arXiv preprint arXiv:2501.01760, 2025.
- [10] W. Yao, M. A. Farooq, J. Lemley, and P. Corcoran, "Synthetic face ageing: Evaluation, analysis and facilitation of age-robust facial recognition algorithms," arXiv preprint arXiv:2406.06932, 2024.
- [11] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, "A simple framework for contrastive learning of visual representations," in Proc. Int. Conf. Mach. Learn. (ICML), 2020, pp. 1597–1607.
- [12] T. Zheng, W. Deng, and J. Hu, "Cross-age LFW: A database for studying cross-age face recognition in unconstrained environments," arXiv:1708.08197, 2017.
- [13] G. B. Huang, M. Ramesh, T. Berg, and E. Learned-Miller, "Labeled faces in the wild: A database for studying face recognition in unconstrained environments," Univ. of Massachusetts, Amherst, Tech. Rep. 07-49, 2007.
- [14] J. Deng, J. Guo, E. Ververas, I. Kotsia, and S. Zafeiriou, "RetinaFace: Single-shot multi-level face localisation in the wild," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2020, pp. 5203–5212.
- [15] T. Gebru, J. Morgenstern, B. Vecchione, J. W. Vaughan, H. Wallach, H. Daumé III, and K. Crawford, "Datasheets for datasets," Commun. ACM, vol. 64, no. 12, pp. 86–92, 2021.
- [16] F. Schroff, D. Kalenichenko, and J. Philbin, "FaceNet: A unified embedding for face recognition and clustering," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), 2015, pp. 815–823.

- [17] J. Deng, J. Guo, N. Xue, and S. Zafeiriou, “ArcFace: Additive angular margin loss for deep face recognition,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2019, pp. 4690–4699.
- [18] M. Kim, A. K. Jain, and X. Liu, “AdaFace: Quality adaptive margin for face recognition,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2022, pp. 18 750–18 759.
- [19] G. Zoss, P. Chandran, E. Sifakis, M. Gross, P. Gotardo, and D. Bradley, “Production-ready face re-aging for visual effects,” ACM Trans. Graph. (SIGGRAPH Asia), vol. 41, no. 6, pp. 1–12, 2022.
- [20] European Parliament and Council of the European Union, “Regulation (eu) 2016/679 (general data protection regulation),” Official Journal of the European Union, L119, 2016.